Studium Licencjackie

Kierunek Metody ilościowe w ekonomii i systemy informacyjne

Imię i nazwisko autora Jakub Rymarski
Nr albumu 114144

Dezinformacja w erze generatywnej sztucznej inteligencji

Praca licencjacka
pod kierunkiem naukowym
dr. Łukasza Skroka
Katedra
Ekonomii Biznesu

Warszawa 2024

Spis treści

Wstęp …… 4

Rozdział I

Dezinformacja …… 6

1.1 Definicja …….. 6

1.2 Przykłady historyczne ....……..... 6

1.3 Teoria autokracji informacyjnej ……..…… 9

1.4 Dezinformacja w dobie internetu i mediów społecznościowych ……..…… 12

1.5 Wyzwania ……..……..……..…… 16

Rozdział II

Generatywna sztuczna inteligencja .....……... 19

2.1 Sztuczna inteligencja …… 19

2.2 Modele generatywne a dyskryminatywne ……..... 20

2.3 Rewolucja z wykorzystaniem generatywnej sztucznej inteligencji ……..... 23

2.4 Przegląd modeli generatywnych ……..... 25

Rozdział III

Wpływ generatywnej sztucznej inteligencji na rozwój dezinformacji ……. 32

3.1 Przedstawienie problemu …..……. 32

3.2 Rodzaje nieprawdziwych treści ……..... 34

3.3 Zagrożenia i wyzwania ……...……..... 36

3.4 Etyka i regulacje prawne ……...……..... 42

3.5 Rozwój generatywnej sztucznej inteligencji a procesy poznawcze ……..... 45

3.6 Zwalczanie dezinformacji za pomocą generatywnej sztucznej inteligencji 47

Zakończenie ……..……..……... 50

Bibliografia ……...……..... 52

Spis rysunków …….……... 55

Streszczenie…….……... 56

Wstęp

W dzisiejszym świecie, za sprawą gwałtownego postępu technologicznego, ludziom dostarczane są ogromne ilości informacji. Powszechny dostęp do internetu sprawił, że wyszukiwanie informacji jest niemal natychmiastowe. Co więcej, chwytliwe tytuły artykułów, zachęcające reklamy produktów i wiele innych atrakcyjnych treści, które wyświetlają się na stronach internetowych, podświadomie przykuwają uwagę internautów. Przestrzeń internetowa wpływa również na inne środki masowego przekazu takie jak prasa, telewizja czy radio, które chętnie przekazują informacje pozyskane ze źródeł internetowych. Szybki, łatwy dostęp do informacji ma wiele zalet jednak rodzi także pewne problemy. W sieci internetowej można rozprzestrzeniać fałszywe i manipulacyjne treści, aby osiągać biznesowe i polityczne cele. Szczególnie czas pandemii COVID-19[1] i wojny na Ukrainie[2] zwrócił uwagę świata na problem dezinformacji. W ostatnich latach pojawiła się także nowa dziedzina sztucznej inteligencji – generatywna sztuczna inteligencja, umożliwiająca tworzenie dużej ilości treści w krótkim czasie. Za jej pomocą można generować bardzo realistyczne teksty, zdjęcia, filmy, ścieżki dźwiękowe, które mogą odnosić się do istotnych kwestii i wykorzystywać wizerunki prawdziwych ludzi np. polityków. Znany przedsiębiorca Warren Buffet uważa, że technologia ta wykorzystana na potrzeby dezinformacji może być bardzo niebezpieczna dla współczesnego świata.[3]

W literaturze zarówno problem dezinformacji, jak i generatywnej sztucznej inteligencji, nie są jeszcze dokładnie zbadane. Większość prac badających ściśle wpływ generatywnej sztucznej inteligencji na dezinformację pochodzi z okresu 2023-2024 r. i dopiero rozważa potencjalne zagrożenia związane z nową technologią i jej wpływem na dezinformację. Przykładowo, tegoroczna praca *Countering Disinformation Effectively*, autorstwa J. Batmana i D. Jacksona[4], skupia się dopiero na przyszłych rozwiązaniach, co pokazuje jak jeszcze mało zbadanym jest niniejszy temat. Dodatkowo, znaczna liczba prac opublikowanych w ostatnim czasie[5] wskazuje jak ważny i pilny jest to problem. Niektóre

---

[1] Meade A., *Facebook greatest source of Covid-19 disinformation, journalists say*, The Guardian, 2020

[2] Bergengruen V., *Inside the Kremlin's Year of Ukraine Propaganda*, TIME, 2023

[3] Ermey R., *Warren Buffett: AI has 'enormous potential for good and enormous potential for harm'*, CNBC, 2024

[4] Bateman J., Jackson D., *Countering Disinformation Effectively*, Carnegie Endowment for International Peace, 2024

[5] 2 590 wyników wyszukania złożenia słów kluczowych "disinformation generative AI" w Google Scholar filtrując wyniki od 2024 r., stan na 18.05.2024 r.

wydarzenia przywołane w tej pracy miały miejsce już po rozpoczęciu jej pisania, tym ciekawiej więc było pisać o aktualnych wydarzeniach.

Celem tej pracy jest analiza zagrożeń związanych z wykorzystaniem generatywnej sztucznej inteligencji w kontekście problemu dezinformacji. Do analizy wykorzystano metody badawcze: przegląd literatury i analizę przypadków.

Pierwszy rozdział pracy poświęcony jest ściśle zjawisku dezinformacji. Omówiona została historia dezinformacji oraz aktualne niebezpieczeństwa i wyzwania z nią związane. W tej części poruszone także zostały kwestie sposobów manipulacji ludźmi i ich podatności na nią.

Drugi rozdział skupia się na opisaniu generatywnej sztucznej inteligencji. Wyjaśniono w nim czym modelowanie generatywne różni się od pozostałych dziedzin sztucznej inteligencji i uczenia maszynowego oraz dlaczego jest istotne dla losów współczesnego świata. Następnie zostały omówione podstawowe koncepcje i algorytmy używane w modelowaniu generatywnym oraz przedstawiono zastosowania różnych modeli generatywnych.

W trzecim rozdziale, na podstawie analizy przypadków, przedstawiono w jaki sposób generatywna sztuczna inteligencja jest obecnie wykorzystywana w szerzeniu dezinformacji. Poruszono tu kwestie wskazywane jako szczególnie narażone na działanie dezinformacji: przeprowadzanie demokratycznych wyborów i zachowanie autorytetu władzy, regulacje prawne oraz wpływ na edukację. Przywołano także wyniki badań opublikowanych w literaturze przedmiotu na temat wiarygodności informacji dostarczanych przez modele generatywnej sztucznej inteligencji. Generatywna technologia może pomóc w tworzeniu nieprawdziwych treści, ale oferowane przez nią możliwości mogą także stać się skutecznym orężem w ich zwalczaniu. Omówione w tej części zostały także sposoby walki z dezinformacją przy użyciu generatywnej sztucznej inteligencji.

Rozdział I

Dezinformacja

1.1 Definicja

Słownik języka polskiego PWN definiuje pojęcie dezinformacji jako „wprowadzenie kogoś w błąd przez podanie mylących lub fałszywych informacji". Warto jednak przyjrzeć się pewnej niekompletności tej definicji. Z pomocą może przyjść nam język angielski, w którym występują dwa podobne słowa – „disinformation" i „misinformation". Według Cambridge Dictionary oba oznaczają wprowadzanie w błąd przy użyciu nieprawdziwych informacji, jednak „misinformation" nie ma charakteru intencjonalnego a „disinformation" jest już działaniem celowym. Mimo tego, że przewodnim tematem pracy jest problem dezinformacji, przydatnym będzie czasami skupić się na samym aspekcie tworzenia nieprawdziwych treści niezależnie od umyślności tego działania.

Jak podaje większość źródeł, słowo „dezinformacja" jest stosunkowo młode. Dean Jackson wskazuje, że pojęcie to powiązywane jest z rosyjskim słowem „dezinformatsiya". Od połowy XX wieku było one używane w ZSRR i oznaczało rozsiewanie nieprawdziwych wiadomości przy użyciu środków masowego przekazu, takich jak radio czy telewizja, w celu zmylenia opinii publicznej. Zdaniem innych historyków słowo to mogło pojawić się już w nazistowskich Niemczech w latach 30. Etymologia słowa nie jest przypadkowa, ponieważ wielu politologów podkreśla, że dezinformacja ma charakter przede wszystkim polityczny. Mówią także oni o zbliżonym pojęciu – propagandzie, które oznacza kierowaną przez władzę zręczną manipulację wybranymi, także często fałszywymi informacjami w celu ukształtowania określonych postaw obywateli. Podobnie jak propaganda, dezinformacja może wykorzystywać również prawdziwe informacje, ale osadzone w zupełnie innym kontekście.[6]

Jest to ważny aspekt przedmiotowy pracy, ponieważ algorytmy sztucznej inteligencji, a szczególnie te tworzące nowe treści, często bazują na prawdziwych danych, które jednak mogą przetwarzać i łączyć tak, aby nadać im zupełnie inny sens.

1.2 Przykłady historyczne

Jak zostało to już wspomniane, początków dezinformacji doszukuje się w totalitarnych reżimach III Rzeszy i ZSRR. Władze tych państw manipulowały nie tylko swoimi obywatelami, ale także opinią międzynarodową. Już Adolf Hitler wiedział jak ważnym

---

[6] Jackson D., *Distinguishing Disinformation from Propaganda, Misinformation, and "Fake News",* International Forum for Democratic Studies, 2017, s. 1, 2

zasobem jest informacja. Naziści inwestowali w kino, radio i inne środki masowego przekazu, aby jak najwięcej ludzi mogło zaznajomić się z wygłaszanymi przez nich ideami. Powołane zostało nawet Ministerstwo Propagandy i Oświecenia Publicznego Rzeszy, którego zadaniem było rozpowszechnianie nazistowskiej ideologii i eliminowanie wszelkiego rodzaju treści sprzeciwiających się poglądom władzy. Na czele ministerstwa stanął Josef Goebbels, który, tak jak Hitler, uważał się za wybitną jednostkę potrafiącą porywać tłumy swoimi przemowami. Jego znane cytaty: „Będziemy pracować nad ludźmi tak długo, aż w końcu ulegną" i „Kłamstwo powtórzone tysiąc razy staje się prawdą" doskonale obrazują myślenie nazistowskich wodzów, którzy mocno wierzyli w sztukę dezinformacji. Ciekawym zabiegiem władz III Rzeszy było wykorzystywanie strategii przywództwa kosztowego. Gazety kontrolowane przez nazistów były tańsze od prasy komunistycznej. Podobnie, produkowano niedrogie odbiorniki radiowe, w których oprócz codziennych audycji rozrywkowych często można było także usłyszeć przemowy Hitlera. Siłą rzeczy, większość społeczeństwa preferowała tańsze produkty nazistowskie. Po pewnym czasie kłamstwo rozprzestrzeniało się już nie tylko za pomocą mediów, ale też podczas codziennych rozmów na ulicach. W kinach prezentowane ludziom były nie tylko nacjonalistyczne niemieckie produkcje jak np. „Triumf Woli", ale także popularne amerykańskie komedie. Z pozoru, była możliwość wyboru repertuaru, jednak przed każdym seansem wyświetlano krótką propagandową kronikę edukacyjną. Te techniki pozwalały nazistom na stopniowe przenikanie do umysłów obywateli, nie narażając się na bunty wywołane ograniczaniem swobód obywatelskich.[7]

Rewolucja październikowa w Rosji była wielkim sukcesem propagandy komunistów. Głosili oni atrakcyjne tezy o równości wszystkich ludzi i wspólnej własności. Robotnicy nie tylko rosyjscy, ale i z całej Europy, a nawet świata połączyli siły. Warto wspomnieć o samej nazwie ugrupowania, którą wymyślił Włodzimierz Lenin. Swoich zwolenników nazwał bolszewikami (ros. „bolsze" - większy) chociaż wcale nie było ich więcej niż jego przeciwników określonych mienszewikamu (ros „miensze" – mniejszy). Można tu zauważyć kolejną sprytną technikę manipulacji.

Niemniej jednak, zasługi bolszewików dla rozwoju dezinformacji są dużo większe. Po zakończeniu I wojny światowej Rosja była wyniszczona. Również wojna domowa i pierwsze nietrafione reformy przeprowadzone przez bolszewików okazały się katastrofalne w skutkach. W kraju zapanował kryzys a ludność żyła w ubóstwie. Lenin zdawał sobie sprawę z tego, że

[7] Weckel U., *Audiences of Nazism: Using Media in the Third Reich*, Berghahn Books, 2023

odbudowa państwa może zająć kilka lat. Związek Sowiecki mógł zostać łatwo podbity. Bolszewicy zdecydowali się więc wykorzystać dezinformację do zmylenia zachodu. Chcieli, aby uważano Związek Sowiecki za silne mocarstwo. Operacja „Sindikat" polegała na przekazywaniu nieprawdziwych informacji zachodnim służbom przez tak zwanych podwójnych agentów sowieckich. „Rezonatory", jak nazywano tych agentów, przeważnie wywodzili się z emigracji, co wzbudzało zaufanie zachodu. Lenin dostrzegł słabość zachodnich agencji wywiadowczych, w których awansowano za dostarczanie informacji. Często nie weryfikowano nawet ich prawdziwości, skupiając się tylko na ich przekazaniu „do góry" i otrzymaniu nagrody. Wskutek sowieckich zabiegów po pewnym czasie w krajach zachodnich panowało mylne przekonanie o szykującym się upadku komunizmu. Pewni swego przywódcy nie skupiali uwagi na bolszewikach, pozwalając im odbudować kraj. Inni agenci natomiast odpowiedzialni byli za „pożyczanie" nowoczesnych technologii, które później wprowadzane były w państwie Sowietów. Co ciekawe, w tym samym czasie bolszewikom zaczęła grozić Japonia pragnąca podbić Syberię. Narracja o słabości państwa mogła tylko zachęcić Japończyków do ataku, dlatego na wschodnim froncie Związek Sowiecki przedstawiany był przez rosyjskich szpiegów jako potęga militarna. Wrogom podsunięto sfałszowane dokumenty o sile wojsk stacjonujących na Syberii, na której działało tylko parę małych oddziałów. Dezinformacja zadziałała i tym razem, do wojny nie doszło.[8]

Warto także cofnąć się na chwilę do wojny polsko-bolszewickiej w latach 1919-1920. Lenin i Trocki przykładali dużą wagę do tzw. agit-propu (agitacji i propagandy). Nie tylko partie komunistyczne w Europie Zachodniej starały się pomóc bolszewikom w walce, ale również wewnątrzpaństwowa manipulacja doprowadziła do poparcia działań wojennych przez społeczeństwo, pomimo wielkiej biedy w kraju. W trakcie wojny utworzono szkoły skupiające się tylko na nauce szerzenia propagandy w Polsce. W szeregach polskiej armii sowieccy agenci rozsiewali nieprawdziwe informacje o zbliżającej się klęsce Polaków obniżając morale żołnierzy.[9]

Kolejnym przykładem dezinformacji jest rywalizacja Stanów Zjednoczonych i Związku Radzieckiego po II wojnie światowej. Zimna wojna była idealnym polem do

---

[8] Świerczek M., *Maki-Miraż, czyli sowiecka sztuka dezinformacji*, Agencja Bezpieczeństwa Wewnętrznego, 2019

[9] Leinwand A., *Propaganda sowiecka w okresie wojny polsko-bolszewickiej 1919-1920 w opinii międzynarodowej: wybrane zagadnienia*, Repozytorium Cyfrowe Instytutów Naukowych, 2009

popisu agencji wywiadowczych obu mocarstw. Powołane w 1947 r. CIA i w 1954 r. KGB prześcigały się w rozsiewaniu dezinformacji, aby przechylić szalę zwycięstwa na swoją stronę. Mocarstwa te starały się zyskać sojuszników angażując się w konflikty polityczne na całym świecie. W Europie po zakończeniu wojny Stany Zjednoczone przeprowadziły kampanie antykomunistyczne, a także pomogły odbudować się zniszczonej Europie ograniczając jednocześnie ingerencję ZSRR na tym obszarze. W 1954 r. Stany Zjednoczone obaliły także prokomunistyczny rząd w Gwatemali usprawiedliwiając swoje działania propagandowymi wiadomościami publikowanymi w miejscowej i międzynarodowej prasie. Analogiczny manewr wykonali w 1980 roku Rosjanie, którzy po inwazji na Afganistan chcieli także przejąć kontrolę nad sąsiednim Pakistanem. Finansowali oni stołeczne media atakujące proamerykański rząd, a także zaangażowali się w szerzenie propagandy w Indiach, aby władze Pakistanu czuły się osamotnione w tej walce. ZSRR i USA interweniowały nie tylko wtedy, gdy miały do tego sposobność wywołaną konfliktami w innych państwach, ale także regularnie się oczerniały. Takim przykładem może być oskarżenie Amerykanów o wyhodowanie wirusa AIDS w celu eksterminacji czarnoskórej populacji lub zarzuty mówiące o zorganizowaniu przez nich zamachu na papieża Jana Pawła II. Sprowokowany rząd USA utworzył nawet w 1981 r. specjalną organizację AMWG (Active Measures Working Group), której głównym zadaniem było zwalczanie sowieckiej dezinformacji. Dwa lata później członkowie tej grupy odwiedzili agencje wywiadowcze wielu państw Ameryki Południowej i Azji przekazując dowody szerzenia przez Rosjan dezinformacji. Sukcesem AMWG było także potwierdzenie przez Michaiła Gorbaczowa fałszywości doniesień o rzekomej odpowiedzialności USA za epidemię AIDS.[10]

1.3 Teoria autokracji informacyjnej

Teoria autokracji informacyjnej opisana przez rosyjskiego ekonomistę Siergieja Guriewa i amerykańskiego politologa Daniela Treismana w publikacji „A Theory of Informational Autocracy" wydanej w 2019 r. obrazuje w jaki sposób współczesne reżimy wykorzystują monopol na przekaz informacji do manipulowania społeczeństwem i osiągania własnych celów politycznych. Szczególny nacisk w pracy położony jest na Białoruś i Rosję, jednak w powyższym dziele mowa jest także o pewnych państwach Unii Europejskiej. Główną cechą autokracji informacyjnej jest brak niezależnych mediów i wolności słowa.

[10] Ward M., Pierson S., Beyer J., *Formative Battles: Cold War Disinformation Campaigns and Mitigation Strategies*, The Wilson Center, 2019

Rozbudowany aparat policyjny pilnuje, aby w społeczeństwie nie dochodziło do podważania informacji podawanych przez rządzących. Paradoksalnie, politycy chcą posiadać pełną wiedzę o swoich obywatelach, dlatego inwestują w służby wywiadowcze. W porównaniu do totalitarnych państw XX wieku, teraz autokracje chcą otwierać się na świat. Proces globalizacji sprawia, że współpraca międzynarodowa się po prostu opłaca. Izolowanie się może doprowadzić do znacznego opóźnienia gospodarczego, jak ma to na przykład miejsce w Korei Północnej. Oczywiście, otwarcie granic powoduje pewien problem dla rządzących reżimów. Kontrolowanie społeczeństwa jest wtedy dużo trudniejsze. Wymiana informacji, międzynarodowe kontakty handlowe, podróże i wiele innych zjawisk, które spowodowała globalizacja, są niebezpieczne dla autorytarnej władzy, ponieważ pozwalają obywatelom wyrobić sobie własne zdanie na dany temat. Ich wiedza nie opiera się już tylko na informacjach, które są im dostarczane w kraju. Ludzie uczą się wtedy myśleć krytycznie. Dlatego właśnie kluczowe jest dla władz, aby mimo wszystko to one kształtowały umysły społeczeństwa. Dobrym przykładem jest walka w Rosji o wpływy na Ukrainie. Skutkiem ukraińskiej „Pomarańczowej rewolucji" była demokratyzacja kraju. Zmiana ustroju w połączeniu z nawiązaniem przez sąsiada kontaktów z zachodem stanowi zagrożenie dla absolutnej władzy Władimira Putina. Istnieje ryzyko przeniknięcia pewnych zachodnich idei na terytorium Rosji, na co Putin pozwolić sobie nie może.[11]

Rozważając dalej przykład Rosji i jej innego sąsiada - Białorusi możemy zobaczyć wiele podobieństw między systemami rządów w obu państwach. Przede wszystkim, istotnym faktem jest to, że w obu reżimach władze sprawuje niewybieralna grupa urzędników stojąca w ich mniemaniu ponad prawem i traktująca własność państwową jak osobistą. Celem ich działań nie jest rozwój państwa a przetrwanie danego systemu politycznego. Oba reżimy próbują całkowicie kontrolować media. Charakterystyczne dla Rosji i Białorusi są też definicje autokracji informacji opisane przez Guriewa. W początkowych latach panowania Putina i Łukaszenki, brak masowych represji wobec przeciwników rządu miał na celu uśpienie czujności społeczeństwa. Gdyby rządzący stosowali powszechny terror ludzie nie wierzyliby w ich dobre intencje. Putin eliminował opozycję bez rozgłosu i starał się pokazywać ją jako wroga kraju. Sam kształtował się na bohatera utrzymującego porządek. Jest to jawny przykład manipulacji społeczeństwem, które często nawet nie zna postulatów głoszonych przez opozycjonistów. Kolejnym aspektem jest odwracanie uwagi społeczeństwa od aktualnych problemów, którym rządzący powinni stawić czoła, ale często nie umieją sobie

[11] Chulkov D., *The phenomenon of information autocracy: content and features*, Refleksje UAM, 2021

z nimi poradzić. Kwestie biedy, zacofania gospodarczego czy spadku produkcji są często wyciszane a wręcz i omijane w mediach. Uwaga jest skupiana na wymyślonych lub wyolbrzymionych problemach. Dobrym przykładem jest odwoływanie się do historii przez rosyjskie władze. Nieustająca pamięć o czasach wielkości ZSRR i ciągła walka z zachodem w drugiej połowie XX wieku usprawiedliwiają zwiększone wydatki na armię. W 2024 r. budżet na wydatki wojskowe wzrósł o 68% w stosunku do poprzedniego roku.[12] Wzniosłe, parady wojska odciągają ludzi od codziennych trudności odwołując się do ich patriotyzmu i narodowej wspólnoty. Ważną rolę w głoszeniu jedynych, słusznych poglądów odgrywają także elity i cerkiew. Pomijając fakt, że prezydenci kształtowani są w środkach masowego przekazu na wspaniałomyślnych, nieomylnych wodzów troszczących się o swój lud, także osoby piastujące wysokie urzędy i inni ludzie sukcesu pokazują, że popierają poglądy władz. Naukowcy, artyści i gwiazdy telewizji są przecież w powszechnej opinii uznawani za ludzi, na których warto się wzorować. Co więcej, nawet przedstawiciele kościoła współpracują z rządzącymi. Dla osób praktykujących wiarę, które uczestniczą w nabożeństwach, duchowni są autorytetami, których słów nie powinno się kwestionować. Oczywiście nie wszyscy członkowie elity czy kościoła zgadzają się z tezami głoszonymi przez rząd, jednak większość władzę popiera. Jak zauważa Chulkov, taka postawa się najzwyczajniej w świecie opłaca. Pisze on o metodzie „marchewki i kija", którą władza wykorzystuje do zjednywania sobie przedsiębiorców czy instytucji. Popieranie propagandy jest sowicie nagradzane, podczas gdy sprzeciw skutkuje nie tylko brakiem finansowego wsparcia, ale i represjami a nawet karami pozbawienia wolności. Mówiąc o represjach nie sposób zapomnieć o znanych przypadkach otruć i zabójstw opozycjonistów. Aleksiej Nawalny czy Borys Niemcow są przykładami ofiar kremlowskiego reżimu. Aleksiej Nawalny stanowczo sprzeciwiający się władzy Putina i ujawniający na zachodzie krwawe tajemnice prezydenta Rosji został najpierw otruty, a później zabity. Warto jednak przyjrzeć się okolicznościom w jakich miało to miejsce. Kiedyś dyktatorzy mordowali swoich przeciwników jawnie, pokazując, że nie będą tolerować aktów sprzeciwu wobec ich władzy. Teraz zabójstwa są dokonywane po cichu a władza odcina się od jakichkolwiek powiązań z daną zbrodnią. Stratedzy polityczni wymyślają przeróżne teorie, mające na celu jak najbardziej wiarygodne zakłamanie historii i odwrócenie uwagi opinii publicznej od danej sprawy. Wielu zachodnich badaczy nie jest w stanie ustalić

[12] *Brytyjski resort obrony: Rosja zwiększa wydatki na wojsko o 68 procent*, PAP, 2023

dokładnych okoliczności zbrodni dokonywanych przez Kreml. Dezinformacja sprawia, że dotarcie do prawdy staje się bardzo trudne lub nawet i niemożliwe.[13]

Przytoczone powyżej zabiegi Rosji mają służyć głównemu celowi autorytarnej władzy – budowaniu wizerunku ustroju państwa jako demokracji. Putin chce kształtować taki obraz państwa zarówno w obywatelach jak i na arenie międzynarodowej. Jeśli chodzi o politykę wewnętrzną wydaje się, że działania reżimu są skuteczne. Władza ma poparcie narodu, na którego świadomość może wpływać kontrolując media. Z badań przeprowadzonych przez naukowców z Uniwersytetu w Chicago w listopadzie 2023 roku wynika, że większość Rosjan popiera Putina i planuje zagłosować na niego w kolejnych wyborach. Ponad 60% obywateli uważa, że Rosja nie jest sprawiedliwe traktowana na arenie międzynarodowej i postrzega wojnę na Ukrainie jako walkę z zachodnimi wpływami w ich kraju. Wydaje się to być postawa zgodna z kremlowską propagandą.[14]

Przyglądając się sytuacji w Unii Europejskiej, także można zauważyć jak rządy państw wykorzystują media i manipulują informacjami w celu osiągania własnych celów. Przykładem tutaj może być protest „żółtych kamizelek" we Francji w 2018 r., kiedy to rząd przekazywał nieprawdziwe wiadomości bagatelizujące problem protestów, np. zaniżał liczbę strajkujących. Kolejnym przykładem są rządy Viktora Orbana na Węgrzech, który po znacjonalizowaniu większości mediów w kraju, zaczął wprowadzać swoje reformy pokazując je w korzystnym świetle. Jednak zdecydowane zwiększenie ingerencji państwa w gospodarkę, przyczyniło się do rozwoju korupcji i pogorszenia sytuacji ekonomicznej kraju.[15]

1.4 Dezinformacja w dobie internetu i mediów społecznościowych

Problem dezinformacji nie ogranicza się tylko do kwestii politycznych i umacniania pozycji państwa na arenie międzynarodowej. Wraz z rozwojem internetu pojawiły się nowe możliwości szerzenia dezinformacji. Teraz niemal każdy w parę minut może stworzyć i udostępnić treści, do których dostęp będzie miała ogromna liczba odbiorców z różnych zakątków świata. Jak podaje raport Digital 2023 w ubiegłym roku ponad 5 miliardów ludzi korzystało z internetu, a 4,76 używało mediów społecznościowych. Obie te liczby zwiększyły się w porównaniu do roku 2022. Z przeprowadzonych badań wynika także, że najwięcej czasu

---

[13] Chulkov D.,... op.cit.

[14] *New Survey Finds Most Russians See Ukrainian War as Defense Against West*, NORC at the University of Chicago, 2023

[15] Chulkov D.,... op.cit.

w internecie spędza się na poszukiwaniu informacji (57,8%), Kolejne dwa miejsca zajmują: pozostawanie w kontakcie z przyjaciółmi i rodziną (53,7%) i co ważniejsze w kontekście niniejszej pracy, bycie na bieżąco z wydarzeniami (50,9%). Warto dodać, że średnio przez 2 godziny i 31 minut dziennie jesteśmy aktywni na mediach społecznościowych.[16] Statystyki te pokazują, jak skutecznym narzędziem w rozsiewaniu nieprawdziwych wiadomości może być internet.

Prawie nieograniczona ilość informacji docierająca do użytkowników stron internetowych powoduje, że podświadomie wpływają one na ich zachowania i opinie. Weryfikacja prawdziwości tych informacji jest więc kluczowa, aby nie zostać wprowadzonym w błąd lub zmanipulowanym. Wirtualny świat oferuje jednak wiele sposobów na szerzenie dezinformacji: „Fake news", „Hoaxes", plotki i teorie spiskowe to tylko nieliczne. Popularne „Fake news" są intencjonalnie napisanymi nieprawdziwymi artykułami internetowymi. „Hoaxes", po angielsku oznaczające „oszustwa", wykorzystują fałszywe groźby i zastraszenia w celu manipulacji ludźmi.[17] Przykładem może być tu opublikowana w 2020 r. przez portal internetowy Daily Buzz Live wiadomość o tym, że NASA przewiduje całkowite sześciodniowe zaćmienie słońca. Mimo szybkiego zdementowania tej informacji przez agencję wielu ludzi zdążyło wpaść w panikę.[18] Wiele komunikatów internetowych ma też zwyczajny charakter plotki, w której nadawcy dzielą się swoimi osobistymi przekonaniami, niepodpartymi wiedzą na dany temat. Idąc jeszcze dalej można wyróżnić „teorie spiskowe", które podważają naukowo udowodnione fakty.[19] Oczywiście, wiele z nich odnosi się do istnienia życia pozaziemskiego, a zainteresowanie społeczne tym tematem przynosi zyski przedsiębiorcom działającym w branży rozrywkowej. Niemniej jednak, niektóre teorie spiskowe często rozpowszechniane przy użyciu internetu wydają się być naprawdę poważną kwestią. Z badań przeprowadzonych w 2023 r. przez popularne czasopismo The Economist wynika, że 20% ankietowanych Amerykanów w wieku 18-29 lat nie wierzy w Holokaust.[20] Zbrodnia ta jest jedną z najlepiej udokumentowanych

---

[16] *Digital 2023: Global Overview Report*, DataReportal, 2023

[17] Shu K., Bhattacharjee A., Alatawi F., Naze T., Ding K., Karami M., Liu H., *Combating disinformation in a social media age, WIREs Data Mining Knowledge Discovery*, 2020, s.2

[18] *Fact check: NASA warning of six days of darkness is a hoax,* USA Today News, 2020

[19] Shu K.,... op.cit., s.2

[20] *One in five young Americans thinks the Holocaust is a myth*, The Economist, 2023

w historii.[21] Czerpiąc jednak wiedzę tylko z być może nawet i przypadkowo odwiedzonych antysemickich witryn internetowych takich jak np. stormfront.org można łatwo zostać oszukanym.

Same funkcje mediów społecznościowych, które pozwalają użytkownikom dzielić się swoimi zainteresowaniami i udostępniać ciekawe treści są idealnym narzędziem do rozsiewania nieprawdziwych informacji. Posty mają często charakter virali (ang. „wirusowy"), które dzięki polubieniom i udostępnieniom szybko docierają do znacznej liczby internautów. Firmy wykorzystują viral marketing jako formę mało kosztownej, ale bardzo skutecznej reklamy swoich produktów. Podobnie czynią to osoby i organizacje mające za cel dezinformację.[22]

Podświadome techniki manipulacji są bardzo często wykorzystywane we współczesnym świecie internetu. W mediach społecznościowych wyświetlają się nam przeróżne reklamy, na które mimowolnie patrzymy przeglądając posty na Facebooku albo czekając na film na YouTubie. W 2018 r. wybuchła afera dotycząca brytyjskiej firmy - Cambridge Analytica, która stosując właśnie takie metody miała wpłynąć na wynik wyborów prezydenckich w USA w 2016 r. Skandal ten zwrócił uwagę świata na problem manipulowania użytkownikami mediów społecznościowych. Firma ta w 2014 r. udostępniła na Facebooku aplikację „This Is Your Digital Life", w której użytkownicy mogli wypełnić test osobowości. Jak się później okazało, aplikacja ta pozwalała na zbieranie danych nie tylko o samych użytkownikach aplikacji, ale także o ich znajomych. W konsekwencji analitycy firmy dysponowali informacjami o obserwowanych stronach, polubieniach i komentarzach pod postami około 87 milionów osób. Zgromadzone dane zostały użyte do analizowania profilów psychologicznych pomocnych w opracowaniu algorytmów, które następnie zostały wykorzystane w manipulowaniu wyborcami. Firma miała wspierać kampanię Donalda Trumpa opracowując strategie działania dla polityków. Analizowano, w których stanach Trump ma szansę przekonać wyborców do oddania na niego głosu i w jaki sposób powinien być przedstawiany, aby zbudzić zaufanie ludzi z danej „grupy psychologicznej". Dzięki takim zabiegom republikanie mogli nie tylko skupić się na kluczowych niezdecydowanych

[21] Cesarani D., *Ostateczne rozwiązanie Losy Żydów w latach 1933-1949*, Prószyński i S-ka, 2019

[22] Shu K.,... op.cit., s.3

wyborcach i tym samym optymalizować wydatki na kampanię, ale także personalizować treści w mediach, tak aby mogły one wpłynąć na zachowanie głosujących.[23]

Przykład tej afery pokazuje jak narzędzia typu Big Data i algorytmy uczenia maszynowego mogą pomóc manipulować ludźmi przez tworzenie odpowiednich strategii personalizacji treści i mikrotargetowania. Autorzy artykułu „The market of disinformation" definiują mikrotargetowanie jako „praktykę wykorzystywania danych użytkowników do kierowania określonych treści do małych, dobrze wyselekcjonowanych grup użytkowników, zamiast publikowania bezosobowych treści na szeroką skalę". Dzisiejsze algorytmy używane nie tylko w branży medialnej, ale także i np. w marketingu, dzielą użytkowników na klastry według ich pewnych wspólnych cech. Cechami tymi mogą być zarówno wiek, rodzaj pracy, miejsce zamieszkania, jak i poglądy polityczne. Rozwój analizy danych i sztucznej inteligencji pozwala na pozyskiwanie coraz to ciekawszych danych z wydawać by się mogło niepozornych źródeł jak np. platformy streamingowe, czy wspomniane już media społecznościowe.[24]

Badanie przeprowadzone w 2014 r. przez naukowców z amerykańskiego Uniwersytetu Cornella na grupie niemal siedmiuset tysięcy użytkowników Facebooka pokazało jak skuteczne mogą być zabiegi mikrotargetowania i personalizacji treści. Badani, niczego nieświadomi internauci zostali poddani eksperymentowi, którego celem było zweryfikowanie możliwości wpływania na ludzkie zachowanie za pomocą portali społecznościowych. Naukowcy personalizowali treści dla danych grup odbiorców. Gdy badanym pokazywano reklamy i posty nacechowane radosnymi, optymistycznymi wiadomościami, oni także udostępniali treści o podobnej tematyce. Co więcej okazało się, że mogą oni wpływać na emocje swoich znajomych, budując wokół siebie przepełnioną miłymi, wesołymi postami internetową rzeczywistość. Wywnioskowano, że obserwując szczęście innych, sami także zaczynamy odczuwać pozytywne emocje. Przeciwnie gdy użytkownikom dostarczano negatywnie zabarwione treści, oni sami zaczęli tworzyć smutne treści, zarażając posępnym nastrojem swoich znajomych. Autorzy badania zauważyli także, że czym więcej treści docierało do użytkownika tym bardziej emocjonalne stawały się jego wpisy. Rezultaty

---

[23] Czubkowska S., *Afera Cambridge Analytica. Facebook wybrał Amerykanom prezydenta. Czy nam też wybierze? I jeszcze na tym zarobi*, wyborcza.biz, 2018

[24] Hoffmann S., Taylor E., Bradshaw S., *The market of disinformation*, The Oxford Technology and Elections Commission, 2019

badania pokazują, jak łatwo można manipulować ludźmi dostarczając im odpowiednie treści w internecie.[25]

Unia Europejska dostrzegła jak wiele negatywnych konsekwencji może mieć mikrotargetowanie. Algorytmy uczenia maszynowego mogą być np. użyte do identyfikacji obaw i lęków w społeczeństwie, a taką wiedzę już nietrudno wykorzystać w manipulowaniu ludźmi. Podkreśla się również, że dotychczasowe regulacje prawne dotyczące np. zgód o przetwarzaniu danych osobowych nie są dobrym rozwiązaniem. Aktualnie większość stron i aplikacji internetowych wymaga zaakceptowania warunków korzystania z usługi i polityki prywatności. Eksperci zwracają uwagę, że czasami jest się zmuszonym skorzystać z danej usługi internetowej i, chcąc nie chcąc, zatwierdza się dane zgody. Dodatkowo, często nie ma się czasu czytać wszystkich szczegółów danej umowy i akceptuje się ją bez zastanowienia. Naukowcy rozważają, czy można uznać akceptowanie takich zgód za świadome. Cały ekosystem internetowy jest teraz zaprogramowany tak, aby uzależnić internautów od użytkowania danych aplikacji, przeglądania konkretnych treści i, w konsekwencji, wykorzystać to uzależnienie do manipulacji. Przepisy Unii Europejskiej o ochronie danych („General Data Protection Regulation"), które weszły w życie w 2018 r. w pewnym stopniu miały za zadanie uregulować powyższe kwestie. Niemniej jednak, jak podkreślał Europejski Inspektor Danych Osobowych, przepisy te dotyczyły raczej ograniczeń w zbieraniu danych niż w samym ich wykorzystywaniu do manipulacji społeczeństwem.[26]

1.5 Wyzwania

Dezinformacja jest złożonym problemem, który nie ma jednego szybkiego i skutecznego rozwiązania. W raporcie „Countering Disinformation Effectively" rozważono pewne sposoby, które mogą być pomocne w zwalczaniu dezinformacji. Wydaje się, że jest potrzeba współpracy na wielu płaszczyznach, aby znaleźć rozwiązanie. Po pierwsze, na problem ten można spojrzeć z czysto ekonomicznego punktu widzenia. Tak jak na rynku ubrań czy samochodów, na rynku nieprawdziwych informacji także możemy uwzględnić podaż i popyt. Wiele firm i organizacji politycznych chętnie oferuje usługi dezinformacyjne zaspokajając potrzeby użytkowników internetu, głodnych kontrowersji i skandali.

---

[25] Kramer A., Guillory J., Hancock J., *Experimental evidence of massive-scale emotional contagion through social networks*, Proceedings of the National Academy of Sciences (PNAS), 2014

[26] Ienca M., Vayena E., *Cambridge Analytica and Online Manipulation*, Scientific American, 2018

Demokratyczni przywódcy walczący z dezinformacją powinni zachowywać się jak inwestorzy, dążący do posiadania zdywersyfikowanego portfela technik przeciwdziałania rozsiewaniu fałszywych informacji. Muszą oni zarówno stosować szybkie skuteczne metody takie jak zwykła weryfikacja treści w interencie, czy dbanie o przejrzyste formy zgód wykorzystywania danych osobowych, jak i planować długoterminową strategię. Strategia ta może obejmować edukowanie społeczeństwa czy współpracę z mediami. Długofalowe inwestycje będą miały charakter prewencyjny. Łatwiej jest nie dopuszczać do dezinformacji, niż prostować wytworzone już fałszywe treści. Naukowcy zwracają także uwagę, że często działania rządów są skupione na sferze internetowej, podczas gdy w takich mediach jak telewizja czy prasa problem może być tak samo poważny. Kolejnym poruszanym w raporcie wątkiem jest pewne ryzyko związane z walką przeciwko dezinformacji. Osoby obmyślające plany naprawy sfałszowanej rzeczywistości powinny pamiętać o tym, że mimo dobrych intencji mogą wykorzystywać te same nieetyczne techniki. Istnieją kontrowersje czy usuwanie nawet nieprawdziwych informacji bez zgody autora jest etyczne lub czy odwołujące się do emocji kampanie przeciwko dezinformacji nie są również manipulacją. Jednym z rozwiązań wydaje się być też „fact-checking" (sprawdzanie faktów), który może np. działać jak aplikacja weryfikująca prawdziwość danej informacji na podstawie algorytmów uczenia maszynowego. Takie podejście wymaga dużych nakładów nie tylko finansowych, ale także pracy wielu ekspertów i co najważniejsze czasu. Na przykładzie nauk ekonomicznych można zaobserwować jak dużo czasu potrzebowała ludzkość, aby polepszyć sytuację gospodarczą na świecie. Wiele lat walczono ze skutkami kryzysów gospodarczych XX wieku. Kwestie dotyczące podatków nadal są szeroko omawiane i budzą wiele kontrowersji. Dezinformacja, która jest zjawiskiem jeszcze mniej zbadanym niż prawa ekonomiczne, może być tematem badań ekspertów jeszcze przez długi czas, zanim wypracowane rozwiązania zostaną zastosowane.[27]

Wraz z gwałtownym rozwojem sztucznej inteligencji a szczególnie tej generatywnej, tworzenie treści, również tych fałszywych, jest coraz prostsze i szybsze. Jak pokazują badania, nawet nie sam stopień realizmu danego faktu a takie czynniki jak: powtarzalność, identyfikacja grupowa czy atrakcyjność mogą bardziej nakłonić ludzi do wierzenia w fałszywe wiadomości. Niewątpliwie rozwój nowych technologii nie ułatwia więc zadania. Można wytwarzać coraz więcej i coraz bardziej atrakcyjnych treści, a wykorzystując

[27] Bateman J.,... op.cit.

mikrotargetowanie wzbudzać w internautach poczucie przynależności do grupy. Paradoksalnie jednak, rozwój nowoczesnych technologii i sztucznej inteligencji, który przyspieszył rozwój dezinformacji, może także pomóc w jej zwalczaniu. Zaawansowane algorytmy potrafią szybciej i efektywniej analizować duże ilości danych. Korzystając z nich, weryfikacja prawdziwości tekstów, filmów i innych treści w internecie może okazać się bardziej skuteczna.[28]

[28] Tamże

Rozdział II

Generatywna sztuczna inteligencja

2.1 Sztuczna inteligencja

Jak sama nazwa wskazuje, pojęcie sztucznej inteligencji generatywnej jest powiązane z tzw. „tradycyjną" sztuczną inteligencją. Skupmy się więc najpierw na niej. Sztuczna inteligencja jest pewnym podobszarem informatyki. Odnosi się ona do technik programowania mających na celu przypominać zachowanie inteligentnych istot. Wystarczy przyjrzeć się pochodzeniom nazw stosowanych w tej dziedzinie algorytmów np. sieci neuronowe czy algorytmy ewolucyjne, które miały naśladować biologiczne procesy zachodzące w ludzkim mózgu. Na inteligentny charakter algorytmów wskazują również typowe zadania, do których używa się sztucznej inteligencji, wymagające umiejętności rozwiązywania problemów, podejmowania decyzji czy rozpoznawania mowy. O tym jak skuteczne narzędzia stworzyła sztuczna inteligencja może świadczyć jej powszechna obecność w codziennym życiu, począwszy od zwykłych wyszukiwarek internetowych po skomplikowane analizy finansowe i diagnozowanie chorób.[29]

Historia sztucznej inteligencji rozpoczyna się w połowie XX wieku. Wojna, jak to już często w dziejach bywało, przyśpieszyła rozwój nowych technologii. Dodatkowo, chęć zrozumienia jak połączyć funkcjonowanie maszyny i organizmu żywego poskutkowała stworzeniem nowej dziedziny nauki – cybernetyki. Starano się w niej wykorzystać zaawansowaną teorię matematyczną i narzędzia elektroniczne do usprawnienia działania maszyn. W 1943 r. Warren McCulloch i Walter Pitts skonstruowali komputerowy model biologicznego neuronu, będący podstawą rozwoju kolejnych konceptów, takich jak chociażby sztuczne sieci neuronowe. Natomiast w 1950 r. Alan Turing w swoim dziele „Computing Machinery and Intelligence" przedstawił test, którego celem miała być weryfikacja tego czy człowiek jest w stanie rozpoznać, czy rozmawia z drugim człowiekiem czy z komputerem.[30]

Powyżej wspomniany aspekt – test Turinga – jest także ciekawy w kontekście niniejszej pracy. Celem sztucznej inteligencji od jej początków było to, aby działanie komputerów przypominało zachowanie człowieka. Dzisiaj życie bez korzystania z urządzeń elektronicznych w rozwiniętej cywilizacji wydaje się niemożliwe. Branża bankowa, opieka zdrowotna i biznes przeniósł się w dużym stopniu do przestrzeni wirtualnej. Komputery, smartfony i inne urządzenia oferują nam usługi oparte na sztucznej inteligencji

---

[29] *Artificial Intelligence: Short History, Present Developments, and Future Outlook*, MIT, 2019

[30] Buchanan B., 2005, *A (Very) Brief History of Artificial Intelligence*, AI Magazine, 2005

a społeczeństwo korzysta z nich często nawet o tym nie widząc. Jak zostało to wspomniane w pierwszym rozdziale tej pracy, szerzenie dezinformacji przy użyciu sztucznej inteligencji może być bardzo skuteczne. Test Turinga pokazuje, dlaczego odróżnienie prawdy od fałszu jest trudnym zadaniem. Można zauważyć pewną analogię np. do fake news, które mogą być tworzone przez sztuczne boty. Mimo to ludzie często nie potrafią odróżnić takiej sztucznie utworzonej treści od prawdziwego artykułu napisanego przez dziennikarza. Niemniej jednak, po wzroście zainteresowania sztuczną inteligencją w latach 50. i 60. XX wieku przyszło spowolnienie jej rozwoju wynikające m.in. z dużych kosztów i braku odpowiedniej infrastruktury. Dopiero w latach 80. gdy ulepszono istniejące i wymyślono nowe algorytmy uczenia maszynowego, w tym uczenia głębokiego (ang. „deep learning"), nastąpiło wznowienie i gwałtowne przyśpieszenie badań. Wielkie korporacje uświadomiły sobie jaki potencjał drzemie w sztucznej inteligencji i inwestowały z zyskami w nowe rozwiązania. Przełomowym momentem, który zwrócił uwagę opinii publicznej na nową szybko rozwijającą się technologię, była partia szachów rozegrana w 1997 roku przez mistrza świata Gary'ego Kasparowa z superkomputerem „Deep Blue" stworzonym przez firmę IBM. Połączenie zaawansowanych algorytmów szachowych i dużej mocy obliczeniowej pozwoliły maszynie ten mecz wygrać. Pokazało to, że umiejętności takie jak rozwiązywanie skomplikowanych problemów i podejmowanie decyzji, utożsamiane dotychczas z ludzkim intelektem, mogą być także skutecznie zaprogramowane i użyte przez maszynę. Przez kolejne lata przedstawiano światu nie mniej atrakcyjne zastosowania sztucznej inteligencji. Tworzono programy do rozpoznawania mowy, konstruowano autonomiczne pojazdy, a komputery wygrywały rozgrywki z mistrzami teleturniejów. Te i inne produkty nie były jednak powszechnie dostępne, dopiero techniki programowania równoległego i opracowanie wydajnych procesorów graficznych, zwiększyły moce obliczeniowe komputerów i pozwoliły zastosować algorytmy sztucznej inteligencji na szeroką skalę.[31]

2.2 Modele generatywne a dyskryminatywne

Słowo „generatywna" w wyrażeniu generatywna sztuczna inteligencja pochodzi od słowa „generować" oznaczającego, jak podaje Słownik języka polskiego PWN, „wytwarzać". Tym właśnie różni się generatywna sztuczna inteligencja od tej „tradycyjnej", mającej za zadanie przewidywanie wyników czy wymyślanie i optymalizowanie strategii. Generatywna sztuczna inteligencja ma za zadanie tworzyć nowe treści na podstawie danych treningowych.

[31] Lawlor P., Chang J., *History of AI: How generative AI grew from early research*, Qualcomm, 2023

Najczęściej wykorzystywana jest do wytwarzania tekstu, obrazu i dźwięku. W skrócie, tradycyjna sztuczna inteligencja radzi sobie z rozpoznawaniem pewnych wzorców i podejmowaniem na ich podstawie decyzji, podczas gdy generatywna sztuczna inteligencja produkuje nowe wzorce.[32]

Modele generatywne mają charakter probabilistyczny. Nie mogą być one deterministyczne, ponieważ wtedy dla takich samych danych dawałyby identyczne wyniki, to znaczy tworzyłyby dokładnie takie same treści, a przecież celem generatywnej sztucznej inteligencji jest tworzenie licznych nowych i różnorodnych obiektów. Mimo bazowania na tych samych danych treningowych, elementy losowe wykorzystane w modelu pozwalają na pobieranie różniących się próbek i, w konsekwencji, umożliwiają otrzymywanie innych wyników. Przeważnie dane wejściowe w problemach generatywnych są nieoznakowane. Modele te są więc wykorzystywane do uczenia nienadzorowanego. Z kolei pod pojęciem tradycyjnej sztucznej inteligencji często rozumie się po prostu inną grupę modeli – modele dyskryminatywne. One z kolei są stosowane przy problemach uczenia nadzorowanego, czyli wtedy, gdy dane treningowe są etykietowane. Pozwala to algorytmowi „uczyć się" za pomocą minimalizacji pewnej funkcji straty obliczanej właśnie dzięki znajomości pożądanych etykiet.[33]

Porównując dwa rodzaje modeli za pomocą notacji matematycznej, można stwierdzić, że modelowanie dyskryminatywne szacuje prawdopodobieństwo, że danej obserwacji X ze zbioru treningowego zostanie przypisana etykieta Y, podczas gdy modelowanie generatywne opiera się po prostu na szacowaniu rozkładów prawdopodobieństwa wystąpienia danych obserwacji ze zbioru treningowego. W pierwszym przypadku kluczowa jest znajomość prawdopodobieństwa warunkowego $P(Y|X)$ a w drugim prawdopodobieństwa $P(X)$. Inaczej mówiąc, w modelu dyskryminatywnym trzeba oszacować prawdopodobieństwo tego, że obserwacja X należy do klasy Y, a w generatywnym prawdopodobieństwo tego i czy w ogóle obserwacja X wystąpi. Dobrze ilustrującym przykładem może być problem dotyczący malowania obrazów. Załóżmy, że mamy dany zbiór treningowy zawierający obrazy namalowane przez Vincenta Van Gogha i innych malarzy. Dana obserwacja jest oznaczona etykietą „1", jeśli twórcą obrazu jest Van Gogh i etykietą „0" w przeciwnym wypadku. Zadanie polega na odpowiedzi na pytanie czy dany obraz został namalowany przez Van

---

[32] Marr B., *The Difference Between Generative AI And Traditional AI: An Easy Explanation For Anyone*, Forbes, 2023

[33] Foster D., *Deep Learning i modelowanie generatywne*, O'Reilly Media, 2023, s.16

Gogha. Oczywiście sprawdzenie będzie odbywało się na zbiorze testowym nieposiadającym etykiet. W tym problemie zdecydowanie pomocny okaże się model dyskryminatywny. Na podstawie pewnych cech obrazu, takich jak na przykład: paleta barw, kompozycja czy kontury kształtów, model ten pozwoli przewidzieć etykietę danego obrazu. Zaklasyfikuje obraz do kategorii „1" gdy uzna, że dzieło z dużym prawdopodobieństwem zostało namalowano techniką charakterystyczną dla Van Gogha, a w innym przypadku zaklasyfikuje obraz jako „0". Dobrze zbudowany model pozwoli na rozpoznawanie dzieł artysty, jednak nie jest w stanie wygenerować nowego obrazu, który byłby podobny do tych namalowanych przez Van Gogha. Stworzenie obrazu namalowanego w sposób charakterystyczny dla holenderskiego artysty nie jest jednak problemem dla modeli generatywnych. Otrzymując na wejściu różne obrazy Van Gogha będą mogły one przeanalizować podobieństwa między nimi. W konsekwencji algorytm „nauczy się" malować jak Van Gogh i będzie w stanie wygenerować kolejne obrazy zgodnie z „wyuczoną" techniką.[34]

Kolejnym przykładem może być nagrana z pomocą sztucznej inteligencji piosenka „Now and Then" autorstwa zespołu The Beatles. Utwór ten wzbudził zainteresowanie światowych mediów, ponieważ jednocześnie występują w nim żyjący Paul McCartney, Ringo Starr, jak i zmarli dekady temu John Lennon i George Harrison. Teledysk i nagranie wydają się być tak realistyczne, że można odnieść wrażenie, że wszyscy muzycy śpiewają razem na żywo w jednym studiu. Dzieło to jednak powstało na bazie trzech taśm z nagraniami. Jednej stworzonej pod koniec lat 70-tych przez Johna Lennona, drugiej nagranej przez trzech pozostałych członków zespołu w 1994 r. i trzeciej powstałej w 2022 r. będącej wynikiem pracy tylko dwóch żyjących Beatlesów. W 1994 r. nie było technologii, która wystarczająco dobrze pozwoliłaby na oczyszczenie domowej taśmy Lennona, dlatego pracę nad piosenką zostały wstrzymane. W 2023 r. algorytmy uczenia maszynowego umożliwiły już jednak wyizolować odpowiednie linie melodyczne z taśmy Lennona. „Nauczyły się" m.in. rozpoznawać głos artysty i inne fragmenty muzyczne tak, że producenci mogli w 2023 r. odpowiednio zmontować całe dzieło. Stworzenie nowego utworu przez nieżyjących już muzyków utożsamiano czasami mylnie w mediach z działaniem generatywnej sztucznej inteligencji. W tym wypadku zwykła sztuczna inteligencja umożliwiła wyodrębnienie

[34] Tamże, s.17

interesujących programistów fragmentów różnych utworów. Nie korzystano z żadnych modeli generatywnych, które wytworzyłyby nowe treści.[35]

2.3. Rewolucja z wykorzystaniem generatywnej sztucznej inteligencji

Warto zastanowić się, dlaczego w ostatnich latach wzrosło zainteresowanie generatywną sztuczną inteligencją. Rozwój ludzkości już od starożytności powiązany był z nowymi wynalazkami. Pismo, druk, czy maszyna parowa były zmianami rewolucyjnymi, wpływającymi bezpośrednio i pośrednio na życie wielu ludzi. Jak ważne to były wynalazki może podkreślać fakt, że wynalezienie ruchomej czcionki przez Jana Gutenberga około 1450 r. jest przez wielu historyków uważane za koniec średniowiecza i początek nowożytności. Podobnie, skonstruowanie maszyny parowej przeze Jamesa Watta w połowie XVIII wieku uznawane jest za początek rewolucji przemysłowej.[36]

Zastanawiając się nad wspólnymi cechami tych i innych wynalazków można dojść do wniosku, że wszystkie one pozwalały na wykonywanie pewnych czynności łatwiej, szybciej i skuteczniej. Dzięki drukowi literatura mogła stać się powszechnie dostępna. Wcześniej skryba mógł przepisywać jedną książkę i kilka lat. Poza umożliwieniem powstania nowych środków transportu, wielką zaletą maszyny parowej było usprawnienie całej produkcji różnego rodzaju dóbr. Wielkie manufaktury uzbrojone w maszyny parowe produkowały nieporównywalnie większe ilości towarów w porównaniu do możliwości wytwórczych jednego rzemieślnika. Kolejne trzy rewolucje przemysłowe miały podobny charakter. Ta druga cechowała się rozwojem elektryczności, dzięki której można było budować urządzenia do badań medycznych czy pracować nad telegrafami. W trzeciej rewolucji przemysłowej główną rolę odegrały mikroprocesory i układy scalone, które umożliwiły masową produkcję komputerów. W tym czasie powstał internet i przyczynił się on do stworzenia globalnej sieci urządzeń elektronicznych. Wszystko to skutkowało znaczącymi zmianami w komunikacji i udoskonaliło środki masowego przekazu i transport. Wreszcie nastała czwarta rewolucja przemysłowa, w której nowe technologie takie jak na przykład internet rzeczy czy chmury obliczeniowe umożliwiają gromadzenie i przetwarzanie ogromnych ilości danych. Pewnym znakiem tej rewolucji stała się inteligentna fabryka, w której praca bazuje na robotach automatyzujących linie produkcyjne. Czwarta rewolucja przemysłowa sprawiła, że informacja

---

[35] Majumder S., *The Beatles are back in the charts, thanks to AI,* Campaign Middle East, 2023

[36] Cameron R., Neal L., *Historia gospodarcza świata*, Książka i Wiedza, 2010

i dane stały się cennymi surowcami, które odpowiednio obrobione i wykorzystane mogą generować ogromne zyski.[37]

Po tym historycznym wstępie można zaobserwować, że generatywna sztuczna inteligencja posiada cechy typowe dla innych wynalazków, które zrewolucjonizowały świat. Dostępne narzędzia Big Data i wydajne chmury obliczeniowe sprawiają, że modele generatywne mogą szybko i efektywnie „produkować", prawie że nieskończone ilości nowych treści, co w czasach „ery informacji" jest rewolucją podobną do tej z udziałem maszyny parowej i zwiększonymi możliwościami wytwórczymi manufaktur. Kolejnym aspektem jest sposób w jaki działa ten nowy wynalazek. Od wieków ludzkość fascynowała się sztuką. To twórcy wybitnych dzieł: pisarze, malarze, rzeźbiarze, kompozytorzy zaspokajali duchowe potrzeby społeczeństwa pragnącego zapisać się w historii ludzkości.[38] Wcześniej wymienione wynalazki, łącznie z komputerami a nawet tradycyjną sztuczną inteligencją nie potrafiły niczego stworzyć. Służyły do usprawnienia pracy czy przeprowadzenia skomplikowanych obliczeń. Odpowiednio zaprogramowany model generatywny umiejętności tworzenia nowych treści już ma, a w dodatku można je uznać za pewną kreatywność - cechę wydawałoby się wyłącznie ludzką.

Zadając pytanie „Czy jesteś kreatywny?" popularnemu chatbotowi ChatGPT, otrzymałem odpowiedź: „Tak, choć moja kreatywność różni się od ludzkiej. Jestem zaprogramowany, aby generować odpowiedzi na podstawie ogromnej ilości danych i algorytmów, co czasem pozwala mi na zaskakujące rozwiązania czy kreatywne podejście do różnych problemów. Jednak moja kreatywność opiera się na analizie wzorców i informacji, a nie na subiektywnych doświadczeniach czy emocjach, jakie mają ludzie."[39] Oczywiście maszyna nie posiada własnego rozumu i inwencji twórczej, ale jej „twórczość" jest oparta na wymyślonych przez człowieka obliczeniach.

Niemniej jednak, jak podkreśla w wywiadzie jeden z twórców ChatGPT, w dzisiejszych czasach ludzie nie są w stanie przeanalizować dokładnego działania algorytmów. Mimo możliwości przejrzenia po kolei kolejnych obliczeń komputera, obliczenia te są na tyle skomplikowane, że nie sposób poznać znaczenia każdej pojedynczej liczby. Zaawansowane mechanizmy matematyczne używane na wielkiej ilości danych sprawiają, że

---

[37] Michalski M., *Od I do IV rewolucji przemysłowej*, Czasopisma UKSW, 2017

[38] Winckelmann J., *Dzieje sztuki starożytnej*, Universitas, 2012

[39] ChatGPT 3.5, OpenAI, Data zapytania: 05.05.2024, godz. 12:40

modele przypominają czarne skrzynki, których zawartość człowiek może poznać, jednak nie potrafi ich całkowicie zrozumieć.[40]

Ta niemoc zrozumienia przez ludzi dokładnego działania algorytmu może być uważana za pewną „kreatywność", która może pomóc generować treści: skutecznie zachęcające do kupna produktów danej firmy, trafnie pobudzające emocje wyborców, a także treści po prostu nieprawdziwe. Wydaje się więc, że ta „umiejętność" nowoczesnych programów jest istotną kwestią w kontekście problemu dezinformacji, pozwalającą maszynom manipulować ludzkim umysłem. Pod obliczeniami w czarnej skrzynce mogą kryć się efektywne techniki dostarczania ludziom niezapomnianych, zaskakujących albo i prowokujących wrażeń, wyzwalających być może jeszcze nieznane dotąd emocje i przedstawiających niezwykle przekonujące narracje.

2.4. Przegląd modeli generatywnych

Modele generatywne dzieli się na jednomodalne (ang. „unimodals") i wielomodalne (ang. „multimodals"). Modele jednomodalne cechują się tym, że przetwarzając dane treningowe jednego rodzaju generują na wyjściu dane w tej samej modalności, tzn. tego samego rodzaju. Innymi słowy, jeśli dostarczy się modelowi dane w postaci tekstu to w rezultacie otrzyma się również tekst, a nie dźwięk czy obraz. Przykładami takich modeli są modele językowe takie jak: GPT albo Bard, a także generatywne modele widzenia komputerowego np. GAN i VAE. Z drugiej strony, modele wielomodalne potrafią obsługiwać i generować różne typy danych jednocześnie. Mogą one przetwarzać dane, które obejmują kombinacje tekstu, obrazu oraz dźwięku i są w stanie analizować związki między nimi. Modele wielomodalne umożliwiają generowanie bardziej złożonych treści w porównaniu do jednomodalnych. Wymagają jednak dużo większej mocy obliczeniowej. DALL-E, jedna z pierwszych aplikacji firmy OpenAI, pokazuje jakie możliwości oferują modele wielomodalne. Aplikacja ta pozwala wygenerować obraz na podstawie wpisanego przez użytkownika tekstu.[41]

---

[40] Wywiad przeprowadzony przez Noama Hassenfelda z pracującym w OpenAI Samem Bowmanem, *Even the scientists who build AI can't tell you how it works*, Vox, 2023

[41] Cao Y., Li S., Liu Y., Yan Z., Dai Y., Yu P., Sun L., *A Comprehensive Survey of AI-Generated Content (AIGC): A History of Generative AI from GAN to ChatGPT*, arXiv:2303.04226, 2023

Jednym z podstawowych modeli, które wykorzystuje się także przy budowie innych jest transformator. Jest to rozbudowana sieć neuronowa, w której wykorzystuje się mechanizm uwagi. Mechanizm ten można opisać jako sposób wybierania najważniejszych informacji z danych. Przeważnie, danemu fragmentowi danych wejściowych model przypisuje pewną wagę, którą odzwierciedla istotność danej informacji w tworzeniu nowej treści. Dobrym przykładem może być tu skupienie się modelu językowego na sensie zdania przy pominięciu warstwy stylistycznej. Transformatory składają się z wielu warstw, które można podzielić na kodery i dekodery. Głównym zadaniem kodera jest przetworzenie danych wejściowych, tak aby w ich nowej, abstrakcyjnej reprezentacji zakodowane już były informacje o wpływie danych fragmentów próbki treningowej na potencjalny wynik. Kolejne warstwy koderów ułożone są w taki sposób, aby wyjście jednego kodera było wejściem drugiego. Dzięki temu można stosować wielopoziomową optymalizację. Zadaniem dekoderów jest odkodowanie zakodowanej prezentacji i tworzenie odpowiedniej treści na jej podstawie. Warstwy dekoderów umożliwiają coraz to dokładniejsze i bardziej trafne generowanie kolejnych sekwencji, aż do otrzymania ostatecznego rezultatu. Transformator jest podstawowym konceptem w uczeniu modeli językowych.[42]

Jednomodalne modele generatywne języka to grupa modeli, służąca do zadań związanych z przetwarzaniem języka naturalnego. Na podstawie danych wejściowych uczą się semantyki, składni i innych typowych elementów ludzkiej mowy a następnie generują treści według poznanych zasad. Wykorzystuje się je m.in. w systemach dialogowych i tłumaczeniach. Modele te bazują przeważnie na architekturze transformatora. Wymagają dość specyficznego przygotowania danych do trenowania. Jako że maszynom wygodniej operować na liczbach niż na słowach, stosuje się wektoryzację. Polega ona na przypisaniu pewnym słowom odpowiednich wektorów, które mają określoną interpretacje dla danego problemu. Najczęściej stosuje się techniki takie jak: Word Embeddings, gdzie wyrazy bliskoznaczne mają przypisane podobne wektory, czy TF-IDF (Term Frequency-Inverse Document Frequency) oparte na częstotliwości słów w tekście. Jeden z najpopularniejszych modeli językowych - GPT (Generative Pre-trained Transformer) jest modelem, którego działanie bazuje na przewidywaniu kolejnego wyrazu na podstawie przetworzonej już sekwencji, tak aby wygenerowany tekst był jak najbardziej spójny. Istotnym elementem procesu uczenia, jako że GPT są powszechnie wykorzystywane w różnego rodzaju

[42] Tamże, s.5

chatbotach, jest uwzględnienie czynnika ludzkiego. Transformatory te dostosowują mechanizm uwagi do opinii udzielanej przez ludzi odnośnie wygenerowanej przez nich treści. Ludzkie oceny wyników modelu stanowią funkcję straty, którą algorytm musi optymalizować dobierając odpowiednio wagi. W nieco inny sposób działają modele służące do tłumaczenia tekstu. Dane treningowe składają się przeważnie z pewnego tekstu wejściowego w jednym języku i jego tłumaczenia w drugim języku. Modele jednocześnie kodują wyjściowy tekst i dekodują tekst przetłumaczony. Znajdują one spójne reprezentacje matematyczne obu tekstów, pozwalające jednoznacznie tłumaczyć poszczególne wyrażenia. Przykładem modelu, który stosuje taką dwustronną naukę uczenia jest BERT. Do trenowania modeli językowych wykorzystuje się przeważnie duże ilości danych pochodzące z różnych źródeł. Można dzięki temu uwzględnić szeroki zasób słownictwa, a także rozpatrzyć różne znaczenia wyrazów w innych kontekstach. Wraz ze wzrostem mocy obliczeniowych komputerów i łatwego dostępu do niezliczonych źródeł danych generowane przez maszyny treści będą coraz bardziej przypominać ludzki język.[43]

Kolejną grupą są modele widzenia komputerowego. Ich głównym zadaniem jest generowanie obrazów i filmów. Stosuje się je w wielu dziedzinach życia. Algorytmy te są podstawowym narzędziem używanym do tworzenia wirtualnej rzeczywistości i grafiki komputerowej, ale mogą być też wykorzystywane w medycynie do generowania obrazów rentgenowskich albo przewidywania wyglądu kolejnych stadiów choroby. Głównym modelem w tej grupie są popularne sieci GAN (Generative Adversarial Networks). Składają się one z generatora i dyskryminatora, które rywalizując ze sobą pozwalają na skuteczny trening. Generator stara się przekształcić wejściowe dane wprowadzając do nich losowy szum. Dyskryminator natomiast próbuje odgadnąć, które obserwacje pochodzą z oryginalnego zestawu danych, a które zostały zmodyfikowane przez generator. Generator ulepsza swoją twórczość w taki sposób, aby dyskryminator nie był w stanie odróżnić sztucznych i prawdziwych danych. Oba mechanizmy iteracyjnie się udoskonalają dzięki czemu model staje się coraz bardziej skuteczny w tworzeniu. Sieci GAN zwracają przeważnie treści podobne do danych treningowych, przez co rzadko stosuje się je do tworzenia całkowicie nowych koncepcyjnie obiektów, jednak ich dużą zaletą jest właśnie tworzenie nowych treści, które wiernie odzwierciedlają daną rzeczywistość. Na przykład w grach komputerowych wykorzystuje się je do tworzenia awatarów. Mając jako dane wejściowe jedną czy dwie

[43] Tamże, s.8

postacie są w stanie generować setki nowych wyglądających równie realistycznie awatarów różniących się noszonym ubraniem czy fryzurą.[44]

Ważnym zastosowaniem sieci GAN jest także augmentacja danych. Podobieństwo generowanych treści do danych treningowych wykorzystuje się, aby rozszerzyć sam zbiór treningowy. Takie zabiegi mogą być pomocne w programowaniu samochodów autonomicznych. Sukces takich samochodów zależy od modeli, które rozpoznają sytuacje na drogach i znajdują odpowiednie rozwiązanie. Samochód widząc przed sobą dziecko powinien zahamować, jednak co się stanie, gdy będzie przed nim jechała na autostradzie ciężarówka z namalowanym na przyczepie dzieckiem? Wtedy gwałtowne hamowanie może spowodować wypadek. W zbieranych przez firmy danych często brakuje takich szczególnych obserwacji, od których w przyszłości może zależeć ludzkie życie. Augmentacja danych z pomocą generatywnej sztucznej inteligencji może więc wzbogacić zbiory treningowe o masę niekonwencjonalnych obserwacji, dzięki czemu trenowanie modeli będzie skuteczniejsze.[45]

Innym modelem widzenia komputerowego jest VAE (Variational Autoencoder). Jak sama nazwa wskazuje, autoenkodery wariacyjne wykorzystują także transformatorowy mechanizm koder-dekoder, jednak tym razem modelowanie ma charakter stochastyczny. Pojęcie „wariacyjny" wskazuje na związek ze statystyką bayesowską. VAE starają się znaleźć rozkład probabilistyczny danych wejściowych i generować obiekty zgodnie z tym rozkładem. Tak więc dodatkowym atrybutem tych modeli jest uwzględnienie rozkładu pewnych zmiennych w populacji, dzięki czemu również w generowanych obiektach dane cechy będą miały podobny rozkład. Na przykład, generując obrazy twarzy model taki uwzględni prawdopodobieństwo wystąpienia różnych kolorów oczu czy konkretnej liczby znamion na policzkach. Najmłodsze w tej grupie są modele dyfuzyjne. Ich działanie opiera się na zaszumieniu danych treningowych a następnie na uczeniu przywracania tych danych do pierwotnego stanu. Trening taki pozwala na wydobycie z danych kluczowych dla tworzenia danego obrazu cech. W modelach tych wykorzystuje się łańcuchy Markowa i inne techniki stochastyczne. Za ich pomocą modeluje się „rozprzestrzenianie" szumu a następnie iteracyjnie odkodowuje się dane z coraz większą dokładnością. Charakter treningu sprawia, że modele dyfuzyjne przydatne są w sytuacjach, gdzie kluczowa jest ostrość i szczegółowość

---

[44] Tamże, s.10

[45] Cooper M., *When Conventional Wisdom Fails: Revisiting Data Augmentation for Self-Driving Cars,* Towards Data Science, 2018

obrazu. Powszechnie stosowane są więc one w diagnostyce medycznej, gdzie każdy najmniejszy detal jest bardzo ważny.[46]

Jak już zostało wspominanie, modele wielomodalne są bardziej złożone od jednomodalnych. Pozwalają analizować interakcje między danymi w różnej postaci. Modele te wykorzystują podobne koncepty i architektury jak modele jednomodalne, jednak są one zdecydowanie bardziej zaawansowane. Wiele modeli wielomodalnych także bazuje na mechanizmie koder-dekoder.[47]

Kodery skonkatenowane składają się z kilku koderów, z których każdy jest odpowiedzialny za przetwarzanie danych w jednej modalności. Przykładowo, jeden z koderów może wykorzystywać model BERT do analizy języka, a drugi analizować obraz używając sieci neuronowych GAN. Następnie, wyjścia poszczególnych koderów są ze sobą konkatenowane tworząc długie wektory reprezentujące już dane we wszystkich modalnościach. Taka reprezentacja umożliwia dalsze wspólne obliczenia dla jednej złączonej całości, a nie dla każdej modalności z osobna. Kolejne podejście do kodowania wielomodalnych danych to kodowanie krzyżowo-wyrównane. To podejście polega na porównywaniu krzyżowo każdej pary modalności i kodowaniu podobieństw i różnic występujących między nimi. W tym przypadku reprezentacja danych jest bardziej zintegrowana niż w kodowaniu skonkatenowanym. Wydaje się, że dzięki temu można analizować dane bardziej kompleksowo.[48]

Dekodery wielomodalne mają z kolei przetwarzać opracowane przed kodery reprezentacje i generować z nich dane w wybranej modalności lub w wielu modalnościach naraz. Najtrudniejszym wyzwaniem dla dekoderów jest zachowanie spójności danych. Często stosuje się w tym celu tak zwane dekodery zamrażające, które pomijają w procesie uczenia część koderów mogąc koncentrować się po kolei na pojedynczych modalnościach. Dopiero później łączą je w jeden spójny obiekt. Dzięki mechanizmowi uwagi mogą opisać dane bardziej szczegółowo. Warto prześledzić działanie dekodera tekst-obraz. Tu również mają zastosowanie sieci GAN działające na podstawie rywalizacji dyskryminatora i generatora. StackGAN jest modelem, który najpierw generuje rozmazany, tylko trochę powiązany z tekstem obraz i w kolejnych krokach poprawia go iteracyjnie analizując dokładniej tekst i,

---

[46] Cao Y.,... op.cit, s.11, 12

[47] Tamże, s.13

[48] Tamże, s.14

jednocześnie, nanosząc zmiany na obraz. Z pozoru podobnie a jednak inaczej działa model StyleCLIP, który wykorzystuje uczenie kontrastowe. Nie uwzględnia on na obrazie podobieństw do tekstu, ale raczej znajduje różnice między danym tekstem a innymi tekstami. Następnie, analizując odpowiadające tym tekstom obrazy, próbuje odróżnić od nich generowany obraz.[49]

Jednym z zadań generatywnej sztucznej inteligencji jest także wytwarzanie dźwięku. Często zatrudnia się maszyny do przeczytania danego tekstu lub skomponowania muzyki. Popularnym algorytmem w generowaniu ludzkiej mowy jest AdaSpeech. Generowanie mowy odbywa się przeważnie sekwencyjnie i wykorzystuje sprawdzony algorytm optymalizacyjny – Adam. Dane treningowe są w postaci nagrań głosowych do tekstów. AdaSpeech realizuje równolegle dwa zadania. Pierwszym z nich jest oczywiście dopasowanie dźwięku do tekstu, ale tym drugim bardziej skomplikowanym jest zachowanie spójności wyjściowej wypowiedzi. Mowa powinna być naturalna i dostosowana do kontekstu. Algorytmy uczą się więc także odpowiedniej intonacji, rytmu a nawet starają się odzwierciedlać emocje. Z drugiej strony, można odwrócić zadanie i generować tekst na podstawie danego dźwięku. Oprócz zwykłego zapisywania słyszanego tekstu można na przykład generować streszczenia i opracowania utworów muzycznych. Modele MusCaps i CLAP wykorzystują architektury wielomodalnych koderów i dekoderów skutecznie tworząc opisy piosenek zawierające nie tylko informacje o tekście piosenki, ale także o melodii, dynamice i instrumentach.[50]

Bardzo ciekawym i, być może, zaskakującym rozwiązaniem jest też generowanie kodu programistycznego. Początkowo duże modele językowe takie jak GPT i BERT miały na celu przetwarzać język naturalny. Jednak wraz z ich rozwojem zaczęto dostrzegać możliwości analizowania przez nie także innych języków, w tym języków programowania. One również posiadają składnię, semantykę, strukturę, a także dane części kodu przekazują określone informacje tak jak ludzkie słowa. Zadanie to wydaje się być więc zbliżone do zadania przetwarzania języka naturalnego. Model CodeBERT jest oparty na dwumodalnym transformatorze, który łączy semantykę języka naturalnego i programistycznego do generowania kodu na podstawie tekstowych instrukcji. Model ten optymalizuje dwie funkcje straty. Pierwsza oparta na złączonych danych języka naturalnego i programistycznego pozwala na dopasowanie kodu do przekazywanych przez użytkownika instrukcji. Druga, wykorzystująca dane w modalności języka programistycznego, odpowiada ściśle za tworzenie

[49] Tamże, s.16

[50] Tamże, s.18

jak najbardziej efektywnego kodu. Uczenie może odbywać się także tylko na podstawie ulepszania samego kodu, w którym tekstowe instrukcje zostały już przetłumaczone na język programistyczny. Modele te są więc często rozbudowywane tak, aby móc automatycznie uzupełniać lub naprawiać dany fragment kodu.[51]

[51] Tamże, s.21

Rozdział III

Wpływ generatywnej sztucznej inteligencji na rozwój dezinformacji

3.1 Przestawienie problemu

W marcu 2023 r. w internecie zaczęło krążyć zdjęcie z papieżem Franciszkiem ubranym w modną puchową kurtkę, w której bardziej wyglądał jak model a nie jak papież. Zdjęcie to zostało stworzone przez generatywną sztuczną inteligencję. Wielu dziennikarzy szybko poinformowało, że obraz modnie ubranego papieża jest nieprawdziwy. Większość użytkowników internetu nie uwierzyła w prawdziwość zdjęcia, jednak przeglądając komentarze i treści na forach można było zaobserwować, że pewna grupa osób jednak uznała to zdjęcie za prawdziwe. Parę dni wcześniej w internecie pojawiły się także zdjęcia aresztowanego prezydenta Stanów Zjednoczonych - Donalda Trumpa. Na niektórych zdjęciach pokazywano go obezwładnianego przez policjantów. Ponownie, na portalach internetowych zapanowała swojego rodzaju konsternacja, dopóki całkowicie nie zdementowano plotek o aresztowaniu, które oczywiście miejsca nie miało. Co ciekawe, wiadomo kto udostępnił wspomniane obrazy. Nie były to żadne tajne organizacje mające na celu rozsiewanie dezinformacji, a zwykli pasjonaci generatywnej sztucznej inteligencji, którzy chcieli pokazać możliwości nowej technologii. Wygenerowane zdjęcia nie miały także znaku wodnego, dzięki czemu specjaliści prawie od razu wywnioskowali, że obrazy te nie były prawdziwe. Przeciętny internauta, nie posiadający odpowiednich narzędzi i wiedzy, mógł jednak uznać te zdjęcia za prawdziwe. Wygenerowany sztucznie obraz niecodziennie ubranego papieża Franciszka jest uznawany za „pierwszy przypadek masowego wprowadzenia w błąd z użyciem sztucznej inteligencji”.[52]

Aplikacje takie jak np. DALL-E pozwalają na generowanie obrazów na podstawie tekstowych poleceń użytkownika. Nie trzeba być piszącym algorytmy doświadczonym inżynierem, aby móc wygenerować śmieszne obrazy z papieżem lub kompromitujące sceny polityków. Modele generujące obrazy często nie potrafią zrozumieć danego kontekstu i skupiają się tylko na wiernym odwzorowaniu wpisanego przez użytkownika polecenia. Użytkownik treści internetowych powinien weryfikować czy wygenerowany obraz nie jest sprzeczny z rzeczywistością. Wydaje się więc, że w tym przypadku udostępnianie fałszywych treści, niezależnie czy w celach humorystycznych, czy mających za cel dezinformację, odbywa się na razie świadomie. Gorsza sytuacja występuje w przypadku modeli tekstowych.

---

[52] Zagni G., Canetta T., *Generative AI marks the beginning of a new era for disinformation*, Europejskie Obserwatorium Mediów Cyfrowych, 2023

Sam charakter treningu modeli takich jak GPT czy BERT polega na przewidywaniu kolejnych słów. Na postawie wielkiej ilości danych zgromadzonych w internecie mogą one sprawnie jak wyszukiwarka internetowa znajdywać podobne treści i konstruować na ich podstawie wypowiedzi. Problemem są jednak dane, które mogą być zarówno prawdziwe jak i fałszywe. Algorytmy bazując na wszystkich dostarczonych danych mogą nie odróżnić istotnej potwierdzonej naukowo informacji od zwykłej teorii spiskowej. Co gorsza, często prawda i fałsz mogą przeplatać się ze sobą, czyniąc wygenerowany tekst bardzo realistycznym i być może nawet prawie całkowicie prawdziwym. Jednak „prawie" ma tu bardzo duże znaczenie, ponieważ użytkownik widząc bardzo realistyczną wypowiedź może jej ślepo zaufać. Dana osoba chcąc uzyskać odpowiedź na temat, który może być jej całkowicie obcy nie będzie potrafiła zweryfikować w pełni prawdziwości informacji dostarczonych przez algorytm. Wydaje się, że w przeciwieństwie do tworzenia obrazów, w wypadku modeli językowych generujących tekst rozsiewanie nieprawdziwych informacji może być nawet przypadkowe.[53]

Rys. 1. Zdjęcia papieża Franciszka wygenerowane przez sztuczną inteligencję.[54]

[53] Tamże

[54] Ellery S., *Fake photos of Pope Francis in a puffer jacket go viral, highlighting the power and peril of AI*, CBS News, 2023

Przykłady wygenerowanych zdjęć papieża Franciszka i prezydenta Trumpa pokazują możliwości sztucznej inteligencji. Nowa technologia może wygenerować zarówno obrazy, które mogą wydać się po prostu zabawne – tak jak zdjęcie papieża w drogiej markowej kurtce, jak i mogą manipulować ludźmi. Widząc np. zdjęcie polityka skazanego na karę pozbawienia wolności, można stracić do niego sympatię. Sztuczna inteligencja może zrewolucjonizować kampanie wyborcze, od których przecież zależą, co najmniej pośrednio, losy świata. W dzisiejszym świecie szybkiego dostępu do niezliczonej ilości informacji kluczowa jest umiejętność krytycznego myślenia. W wygenerowanej przez model językowy wypowiedzi, zawierającej kilka powszechnie znanych faktów i brzmiącej bardzo realistycznie, jedno kluczowe zdanie może okazać się fikcją. Tak jak już zostało wspomniane w rozdziale poświęconym omówieniu sposobów działania modeli generatywnych, modele językowe mają za zadanie nie tylko zawrzeć w wygenerowanej odpowiedzi istotne dla danego problemu informacje, ale także chcą upodobnić charakter wypowiedzi do ludzkiej mowy. Połączenie realizmu tekstu i ludzkiego charakteru wypowiedzi może sprawić, że użytkownik całkowicie zaufa wygenerowanej odpowiedzi. W trudnej sytuacji znajdzie się osoba, która natknie się na daną treść na portalu internetowym nie wiedząc, że została ona wygenerowana przez sztuczną inteligencję. Może ona nawet nie odróżnić danego tekstu od wypowiedzi człowieka.

3.2 Rodzaje nieprawdziwych treści

Generatywna sztuczna inteligencja oferuje wiele możliwości. Z jej pomocą można przetwarzać i generować dane różnego rodzaju. Dezinformacji mogą służyć nieprawdziwe obrazy, filmy, teksty, a nawet dźwięki. Fałszywe zdjęcia i filmy generowane przez sztuczną inteligencję oznacza się często pojęciem „Deepfake”. Jest to połączenie słowa „deep”, odnoszącego się do metod głębokiego uczenia maszynowego, i „fake” oznaczającego nieprawdziwą informację. Jak podaje słownik „Britannica”, „Deepfake” oznacza „wytworzone przez sztuczną inteligencję zdjęcia i filmy, które ukazują obiekty, które nigdy nie istniały i wydarzenia, które nigdy nie miały miejsca”.

Oprócz nieprawdziwych zdjęć i filmów narzędziami dezinformacji mogą być także nieprawdziwe teksty i klonowanie głosu. Nieprawdziwe treści przekazywane za pomocą filmów pokazują przeważnie zmyślone czynności wykonywane przez prawdziwych ludzi. Trening sieci GAN pozwala na odzwierciedlenie na filmie zachowania i charakterystycznych cech danej osoby. Szczególnie wdzięcznymi bohaterami takich filmów są osoby publiczne,

takie jak politycy i aktorzy. Ich wizerunki i nagrania z ich udziałem, które nietrudno znaleźć w internecie, mogą stanowić ogromną bazę danych dla modelu. W 2021 r. na platformie TikTok została opublikowana seria krótkich filmów, w których pojawiła się postać łudząco podobna do Toma Cruise'a. Postać ta została wygenerowana przez sztuczną inteligencję, ale wyglądała, mówiła i zachowywała się jak ten popularny amerykański aktor. Kanał DeepTomCruise od początku miał za zadanie ukazać potężne możliwości sztucznej inteligencji, jednak filmy tańczącego w szlafroku albo uczącego internautów myć ręce aktora mogłyby także posłużyć innym celom. Warto zauważyć, że filmy te wymagały specjalistycznego sprzętu, w tym drogich kart graficznych. Charakterystyczne dla Toma Cruise'a ruchy pomógł odtworzyć także profesjonalny aktor. Przedsięwzięcie to było więc efektem pracy wielu ludzi. Osiągnięcie bardzo dobrych efektów nie było więc zadaniem prostym, niemniej jednak okazało się możliwe. W wypadku filmów, które nie mają aż tak idealnej jakości, ale również wydają się bardzo realistyczne, tak drogie wydatki nie są potrzebne. Wiele darmowych aplikacji oferuje możliwości tworzenia nieprawdziwych filmików nawet ze swoim udziałem. Wystarczy załączyć swoje zdjęcie twarzy, a algorytmy wygenerują odpowiednią treść.[55]

Przetworzone zdjęcia ludzi mogą podobnie jak filmy przedstawiać prawdziwe osoby w sytuacjach, które się nie wydarzyły, ale co ciekawsze, sztuczna inteligencja może generować także zdjęcia nieistniejących osób. W 2019 r. na portalu społecznościowym LinkedIn został utworzony profil niejakiej Katie Jones. Bardzo ładna Rosjanka studiująca w Stanach Zjednoczonych i pracująca w poważanej instytucji - Centrum Studiów Strategicznych i Międzynarodowych - wysłała zaproszenie urzędnikowi administracji prezydenta Trumpa. Profil ten okazał się być jednak sztucznym kontem utworzonym przez rosyjskich szpiegów. Zabiegi takie są powszechnie stosowane na innych portalach społecznościowych takich jak Instagram czy Facebook. Zaproszenia do grona znajomych lub wpisy na zaufanych forach mogą posłużyć do kradzieży danych lub manipulacji internautami.[56]

Generowanie nieprawdziwych tekstów jest jedną z najbardziej rozpowszechnionych metod rozsiewania dezinformacji. Z pomocą generatywnych modeli językowych można tworzyć szybko duże ilości tekstów. W ostatnich latach zaczęło powstawać coraz więcej botów generujących sztuczne treści w różnym celu. Przykładem może być tu propaganda

---

[55] Helmus T., *Artificial Intelligence, Deepfakes, and Disinformation*, JSTOR, 2022, s.2, 3

[56] Tamże, s.4

stosowana przez chiński rząd. W regionie Xinjiang wykorzystuję się niewolniczą pracę muzułmańskich Ujgurów do wytwarzania bawełny. W internecie pod hasztagiem Xinjiang udostępnianych jest wiele treści pokazujących tragiczne warunki pracy robotników. Komunistyczne władze stworzyły jednak liczną grupę botów, które pod tym hasztagiem udostępniają malownicze widoki pól uprawnych i piękne bawełniane wyroby. Tym propagandowym działaniem zakłamują w mediach rzeczywistość.[57]

Kolejnym skutecznym narzędziem dezinformacyjnym może być klonowanie głosu. Metoda ta może zwiększyć realizm filmu wideo lub zostać samodzielnie wykorzystana jako materiał radiowy. Wiele aplikacji pozwala na podrabianie głosów polityków i celebrytów. Zdarzają się przypadki, gdy naśladowanie głosu można wykorzystać do kradzieży. Znane są przypadki, gdy ojciec przelał znaczną kwotę po rozmowie telefonicznej z botem mówiącym głosem płaczącego syna lub gdy pracownik korporacji zrealizował przelew zgodnie ze wskazówkami podrobionego głosu szefa firmy.[58]

3.3 Zagrożenia i wyzwania

Wagę problemu dezinformacji w erze generatywnej sztucznej inteligencji ukazują wyniki badań Światowego Forum Ekonomicznego. W raporcie „Global Risk Report 2024" omówione zostały największe globalne zagrożenia dla ludzkości. Raport przedstawia wymagające pilnej uwagi, ryzyka i niebezpieczeństwa czekające świat z perspektywy trzech ram czasowych - jednego roku, dwóch lat i dziesięciu lat. Okazuje się, że dezinformacja jest i ma być nadal jednym z głównych wyzwań ludzkości. W perspektywie jednego roku najczęściej wskazywanym przez specjalistów zagrożeniem dla współczesnego świata była ekstremalna pogoda („Extreme weather"). Ma to związek z gwałtownymi zmianami klimatycznymi, które szczególnie dotkliwie dały o sobie znać latem 2023 r. Niemniej jednak, drugą pozycję w rankingu zajęły mylne i nieprawdziwe informacje generowane przez sztuczną inteligencję („AI-generated misinformation and disinformation"). Co więcej, trzeci najpilniejszy problem to społeczna i polityczna polaryzacja. Eksperci wskazywali na ścisły związek dezinformacji z podziałami politycznymi i społecznymi. Wykorzystanie generatywnej sztucznej inteligencji w celach dezinformacyjnych może być poważnym zagrożeniem dla demokratycznych wyborów. Z kolei w perspektywie dwóch najbliższych lat to już właśnie problem dezinformacji jest wskazywany jako ten najbardziej istotny. W tym

[57] Tamże, s.5

[58] Tamże, s.4

okresie prawie trzy miliardy mieszkańców Ziemi będzie dokonywało wyborów władz. W 2024 r. odbędą się wybory prezydenckie w Stanach Zjednoczonych i wybory parlamentarne w Indiach. W 2025 r. prezydenta będą wybierać Polacy. Eksperci z Indii jako największe ryzyko związane z ich państwem wskazali właśnie zbliżające się wybory.[59]

Wydaje się, że opisane powyżej obawy są uzasadnione. Już w przypadku wyborów do Zgromadzenia Ustawodawczego w Delhi w 2020 r. zanotowano ciekawy przypadek wykorzystania generatywnej sztucznej inteligencji w kampanii wyborczej. Szef Indyjskiej Partii Ludowej Manoj Tiwari nagrał filmik w języku haryanvi, w którym skrytykował przeciwników i zachęcił do głosowania na niego w wyborach. Sztab wyborczy polityka zwrócił się dodatkowo o pomoc do firmy zajmującej się sztuczną inteligencją w celu ulepszenia nagrania. Przemówienie w tradycyjnym języku mogło przyciągnąć pewną część wyborców, jednak dla innej, nieznającej tego języka grupy, nagranie było niezrozumiałe. Sztucznie wygenerowano więc filmik, w którym polityk mówi po angielsku, a następnie połączono oba nagrania w jedno, tak aby wyglądało to tak, że Tiwari mówi zarówno w języku haryanvi, jak i po angielsku. Szacowano, że pozwoliło to dotrzeć politykowi do nowych 15 milionów wyborców. Jak się okazało Tiwari wyborów nie wygrał, jednak mimo wszystko generatywna sztuczna inteligencja znacząco pomogła mu w przeprowadzeniu kampanii wyborczej.[60]

Innym przykładem mogą być wybory prezydenckie, które odbyły się w lutym 2024 r. w trzeciej największej demokracji na świecie – Indonezji. Generał Prabowo Subianto w dwóch poprzednich kampaniach nie zdołał odnieść sukcesu. Budował on wtedy swój wizerunek jako surowego, zdyscyplinowanego żołnierza nacjonalistę. W tych wyborach postanowił zmienić strategię i przedstawiać się jako miły, delikatny władca. Całkowita zmiana wizerunku nie była prostym zadaniem, jednak z pomocą generatywnej sztucznej inteligencji polityk osiągnął zamierzone efekty. Sztuczna inteligencja wygenerowała uroczą kreskówkową postać generała Subianto. Seria plakatów wyborczych i filmików z animowanymi postaciami najwyraźniej pomogły przekonać znaczną część społeczeństwa do zagłosowania na Subianto. Wygrał on wybory osiągając szczególnie wysokie poparcie młodszych wyborców. W Indonezji kolejną pomocą dla polityków miała okazać się aplikacja Pemilu.AI. Aplikacja ta na postawie danych pobranych z aplikacji społecznościowych mogła

---

[59] *The Global Risk Report 2024*, World Economic Forum, 2024

[60] Turek A., *W indyjskiej kampanii wyborczej wykorzystano oficjalnie spreparowane nagrania*, Business Insider, 2020

generować odpowiednie slogany i hasła wyborcze dla konkretnych okręgów. Wydaje się, że rewolucja w kampaniach wyborczych już się zaczęła.[61]

Rys. 2. Plakat w kampani Prabowo Subianto.[62]

Przykłady te pokazują, że generowane przez sztuczną inteligencję treści w kampanii wyborczej nie muszą koniecznie opierać się na tworzeniu kompromitujących zdjęć i filmów z udziałem rywali, ale mogą np. ułatwić politykowi nabycie nowych cennych umiejętności lub całkowitą zmianę wizerunku. Osoba nieznająca obcego języka może się go szybko „nauczyć", a słaby mówca może nagle zacząć lepiej modulować głos i odpowiednio gestykulować. Politycy mogą także zmieniać swój wizerunek w zależności od potrzeb. Prezydent Subianto będąc przez całe życie zagorzałym nacjonalistą mógł w ciągu paru miesięcy całkowicie zmienić swój wizerunek. Można wyobrazić sobie także sytuację, gdy sztaby będą generować zdjęcia z politykami walczącymi ramię w ramię z żołnierzami lub

[61] Lamb K., Potkin F., Teresia A., *Generative AI may change elections this year. Indonesia shows how*, Reuters, 2024

[62] *The Cute Grandpa*, Medium, 2024

ratującymi dzikie zwierzęta w dżungli. Zdjęcie takie można wygenerować w kilka chwil. Co więcej, można wygenerować miliony podobnego typu zdjęć w krótkim czasie. Nie tak łatwo będzie zweryfikować autentyczność ich wszystkich. Sztuczna inteligencja może także generować teksty i spoty, które będą poruszały problemy ważne dla danej grupy wyborców. Wykorzystując dodatkowo mikrotargetowanie można nawet jednocześnie przekonywać do głosowania na siebie grupy ludzi o skrajnie różnych poglądach.

Dezinformacja nie jest problemem tylko krótkoterminowym. We wspomnianym raporcie Światowego Forum Ekonomicznego również w perspektywie lat dziesięciu dezinformacja zajmuje piąte miejsce. Wyprzedzają ją tylko kwestie związane z różnymi katastrofami naturalnymi. Na szóstym miejscu uplasowały się inne jeszcze nieznane zagrożenia związane ze sztuczną inteligencją. Parę lat temu nie spodziewano się, że powstanie nowa technologia, która pozwoli na tworzenie wszelkiego rodzaju treści, rewolucjonizując wiele aspektów życia codziennego. Podobnie teraz nie wiadomo w jaki sposób wyewoluuje sztuczna inteligencja. Jak gwałtownie rozwinął się problem dezinformacji może także świadczyć fakt, że w tym samym raporcie dotyczącym roku 2023, dezinformacja znajdowała się aż 15 miejsc niżej w kategorii globalnych zagrożeń w perspektywie dwóch lat. Warto także zauważyć, że takie zagrożenia jak bezrobocie, rosnąca inflacja, migracje czy przemoc, są niżej w rankingu. Wraz z rozwojem nowych technologii ilość generowanych nieprawdziwych treści gwałtownie wzrasta. Istnieje ryzyko, że społeczeństwo powoli zacznie tracić zaufanie do źródeł informacyjnych, a tym samym do wszelkiego rodzaju instytucji. Szacuje się, że w internecie będzie krążyć coraz więcej manipulacyjnych treści promujących własne ideologie i myśli polityczne. W konsekwencji w społeczeństwie dojdzie do jeszcze większych podziałów. Nie mając pewnych źródeł informacji ludzie zaczną podważać także autorytet władzy. Nowo wybrane rządy nie będą w stanie utrzymać władzy. W społeczeństwie mogą rozpowszechnić się wtedy postawy anarchistyczne, przestępcze, a może i terroryzm. Fałszywe informacje mogą być także wykorzystywane w biznesie. Firmy za pomocą sztucznie wygenerowanych reklam mogą ukazywać produkcję swoich produktów jako przyjazną naturze, a w rzeczywistości będą zatruwać powietrze przyczyniając się do katastrofy klimatycznej. Powszechna nieufność może skutkować także destabilizacją polityczną i gospodarczą w państwie. Działanie nie tylko urzędów, ale i placówek zdrowotnych i edukacyjnych, może zostać poddane w wątpliwość. Nastąpi kryzys gospodarczy i pogorszy się życie obywateli. Wyzwaniem dla rządzących będzie ustanowienie

odpowiednich regulacji prawnych. Bezczynność władzy doprowadzi do nieograniczonego wzrostu dezinformacji, z kolei zbyt ostre i szybkie działanie może być utożsamiane z brakiem wolności słowa i spowodować bunty społeczne. Niemniej jednak, nawet odpowiednie przepisy mogą nie powstrzymać rozwoju dezinformacji. W Chinach wprowadzono regulacje, na podstawie których wszystkie treści wygenerowane przez sztuczną inteligencję muszą być oznaczone konkretnym znakiem wodnym. Rozwiązanie takie wydaje się być sensowne, jednak należy pamiętać, że w pędzącym świecie dostępu do niezliczonej ilości informacji wiele osób na taki znak może nie zwrócić uwagi. Tak jak już zostało to wspomniane, ludzie często nie czytają nawet zgód dotyczących przetwarzania danych osobowych. Nawet gdy internauta zauważy, że dana treść jest fałszywa, już sam jej przekaz może na niego odpowiednio wpłynąć.[63]

Jak silnie może oddziaływać na społeczeństwo dezinformacja mogą pokazywać wyniki badań dotyczące poparcia Polaków dla pomocy ukraińskim uchodźcom. Jak podaje Centrum Badania Opinii Społecznej coraz mniej Polaków chce pomagać Ukraińcom, którzy uciekli do Polski po wybuchu wojny w 2021 r. W marcu, zaraz po napaści Rosji na Ukrainę, ponad 90% Polaków deklarowało chęć pomocy uchodźcom. Z kolejnymi miesiącami poparcie jednak spadało. Początkowo spadki były minimalne, lecz po roku procent poparcia był już liczbą rzędu 80%, a w kwietniu 2023 r. poparcie osiągnęło rekordowo niskie 73%. Interesujące, że najmniejsze poparcie 64% zanotowano w grupie wiekowej 18-24 lata. W wyższych grupach wiekowych poparcie było zdecydowanie wyższe i wyniosło 81%. Również czynniki takie jak wykształcenie i płeć determinowały poziomy poparcia. Ludzie z wyższym wykształceniem zdecydowanie częściej opowiadali się za pomocą dla uchodźców. Zaskakujący może być też fakt, że najmniejszą chęć do pomocy wykazywały kobiety w wieku 18-24 lata. Eksperci sądzą, że może być to konsekwencja tego, że większość uchodźców to kobiety, w tym również i potencjalne młode rywalki szukające mężów.[64]

Zwiększona niechęć do pomocy Ukraińcom na pewno - jak to zauważono w powyższym badaniu - ma w pewnym stopniu związek z obawami o własną sytuację materialną Polaków. Niemniej jednak, nie tylko sama niechęć, ale też i wszelkiego rodzaju obawy, mogą mieć źródła w dezinformacji rozsiewanej przez Rosjan i prorosyjskie portale. Zaraz po wybuchu wojny nie tylko w mediach, ale i na ulicach można było zaobserwować

---

[63] *The Global Risk Report 2024*,... op.cit.

[64] *Polish Public Opinion*, CBOS, 2023, s.1

zaangażowanie polskiego społeczeństwa na rzecz pomocy wojennym uchodźcom. Media przepełnione były informacjami o potrzebie pomocy Ukraińcom i pokazywały wzruszające sceny z udziałem pomagających polskich obywateli. Z czasem jednak Rosjanie zaczęli masowo atakować polskie media nieprawdziwymi informacjami o wojnie i sytuacji w Polsce po przyjęciu uchodźców, mające zniechęcić Polaków do niesienia pomocy Ukrainie. Szerokie zasięgi zdobywały nawet tak oddziałujące na emocje wiadomości jak rzekome wyrzucanie polskich dzieci z oddziałów onkologicznych w celu zwolnienia miejsc dla dzieci ukraińskich. Mimo tego, że doniesienia te były dementowane przez lekarzy, nieprawdziwe informacje mogły zdążyć zasiać niepokój w polskich obywatelach. W mediach społecznościowych zaczęło powstawać wiele blogów prorosyjskich przedstawiających Rosjan jako stronę poszkodowaną w tym konflikcie. Manipulacja odbywała się nie tylko za pomocą nieprawdziwych informacji, ale także przywoływano historyczne polsko-ukraińskie konflikty. Co więcej, konkretne treści mające odwieść uwagę mediów od zbrodni dokonywanych na Ukrainie generowano w strategicznych momentach. Na początku kwietnia 2022 r. wraz z informacjami o mordzie ukraińskiej ludności w Buczy w internecie zanotowano zwiększoną liczbę odpowiednio skonstruowanych wiadomości przypominających o bolesnej dla Polaków Rzezi Wołyńskiej. Wiele treści było tworzonych sztucznie z użyciem botów, dzięki czemu Rosjanie mogli zwiększyć ilość nieprawdziwych informacji w bardzo szybkim tempie.[65]

Dezinformacja jest najczęściej rozprzestrzeniana za pomocą internetu i mediów społecznościowych. To właśnie osoby w wieku 18-24 lata najczęściej korzystają z portali społecznościowych według badań przeprowadzonych przez CBOS. Widać więc, że na nich dezinformacja mogła wpłynąć najbardziej. Najmłodsze pokolenie dorosłych wychowywało się już w dobie powszechnego dostępu do platform takich jak YouTube, Facebook czy Twitter. Nieprawdziwe informacje przedstawiane w formie krótkich filmów czy postów mogą być dla nich z pozoru niewinnymi, zwykłymi treściami, podobnymi do tych które codziennie przeglądają już od kilku lat. W świecie, w którym - jak pokazują badania - również w starszych grupach wiekowych odsetek ludzi korzystających z internetu i posiadających konta na portalach społecznościowych cały czas wzrasta[66], dezinformacja będzie stawała się coraz groźniejszym problemem.

---

[65] *Russia's key disinformation narratives addressed to Poles - Fakehunter analysis,* PAP SA

[66] *Korzystanie z internetu*, CBOS, 2022

Innym przykładem dezinformacji dążącym do destabilizacji państwa mogą być działania blogów czy stron takich jak MIR.tv – Media Informacje Relacje. Ta powszechnie dostępna strona na portalu Facebook już samą swoją nazwą wskazuje na konotacje z Rosjanami. Obserwując treści na tym portalu można odnieść wrażenie, że koncentrują się one głównie na podważaniu autorytetu władzy i wywoływaniu konfliktów w społeczeństwie. Wysłannicy tej „stacji" podburzali rolników na odbywających się w marcu 2024 r. protestach. Mówili o dobrobycie ukraińskich rolników sprzedających towary w Polsce wzbudzając do nich niechęć i negując przy okazji fakt istnienia wojny na Ukrainie.

W kwietniu tego samego roku na portalu tym prowadzono transmisję, podczas której wylano przed budynek kancelarii premiera substancję przypominającą błoto. Nie jest wykluczone, że wydarzenie to zostało zainicjowane przez Rosjan, a następnie wykorzystane w celach propagandowych.[67]

Wcześniej, w czasie pandemii COVID-19, na kanale tym pojawiały się treści z nieprawdziwymi informacjami na temat szczepionek i leków. Zdementowała je chociażby jedna z pierwszych w Polsce organizacji zajmujących się weryfikacją wiadomości (fact-checking)[68].

Treści udostępniane przez MIR.tv i inne podobne portale mają na celu skłócić społeczeństwo i doprowadzić do destabilizacji państwa. Większość postów na stronie MIR.tv cieszy się dużym zainteresowaniem, a internauci komentują je pochwalając działania kanału. Ma on prawie 200 tysięcy obserwujących. Problem ten pokazuje, że dezinformacja nie jest wymyślonym zagrożeniem, lecz już wielu ludzi mogło ulec w większym lub mniejszym stopniu manipulacji. Nie można także zapomnieć, że zasięgi w mediach społecznościowych mogą być budowane za pomocą sztucznych kont i stworzonych z pomocą generatywnej sztucznej inteligencji botów piszących z pozoru niczym nieróżniące się od tych ludzkich komentarze.

3.4 Etyka i regulacje prawne

Kolejny długoterminowy problem w kontekście rozpowszechniania dezinformacji z użyciem generatywnej sztucznej inteligencji jest związany nie tyle nawet z samą zawartością danych treści, co z faktem kto treści te tworzy. W raporcie „Digitally Divided: Technology, inequality, and human rights" opracowanym przez Amnesty International,

---

[67] *Incydent przed Kancelarią Premiera. Pytania o możliwy związek z działalnością obcych służb*, TVN, 2024

[68] *Amantadyna, szczepienia, COVID-19 i lek. Ratkowska*, Demagog, 2023

organizację zajmującą się ochroną praw człowieka, przedstawione zostały niebezpieczeństwa dla społeczeństwa wynikające z pewnych wad algorytmów sztucznej inteligencji. Niewątpliwie nowe technologie mogą ułatwić ludziom życie w wielu aspektach, jednak mogą także przyczynić się do wzrostu nierówności społecznych i spowodować wiele konfliktów. Eksperci podkreślają, że niektóre współcześnie stosowane algorytmy są po prostu nieetyczne, utrwalają zakorzenione w kulturze krzywdzące stereotypy i opierają się na niesprawiedliwych regulacjach mających swój początek jeszcze w erze kolonializmu. Władza na świecie skupiona jest w rękach niewielkiej grupy ludzi. Szacuje się, że garstka możnych tego świata posiada 76% wszystkich dóbr ziemskich, podczas gdy rzesza biednych ludzi zarządza tylko 2% tych dóbr. W ostatnich latach nierówności społeczne się pogłębiają. Wielkie koncerny mające swoje siedziby w bogatych państwach rozwijają nowe technologie. To one decydują, na jakich danych będą trenowane algorytmy i mogą kontrolować treści ukazujące się w ich produktach np. w wielu mediach społecznościowych. Kontrolę nad globalnym źródłem informacji – internetem, sprawuje nieliczna grupa ludzi. To od nich zależy jak będzie wyglądał wirtualny świat i w jaki sposób będzie działać generatywna sztuczna inteligencja. Istnieje ryzyko, że świat stanie się swego rodzaju teatrem z nieliczną grupą reżyserów – technologicznych gigantów, polityków i innych wpływowych ludzi.[69]

Eksperci dostrzegają potrzebę opracowania konkretnych przepisów regulujących zasady korzystania ze sztucznej inteligencji. W marcu 2024 r. Parlament Europejski zatwierdził akt w sprawie sztucznej inteligencji „EU Artificial Intelligence Act". Przepisy dotyczące sztucznej inteligencji wejdą w życie prawdopodobnie za parę lat, lecz samo ich opracowanie i zatwierdzenie przez Parlament można uznać za wydarzenie przełomowe. W dokumencie tym zostały poruszone kwestie mające zapewnić zrównoważony rozwój nowej technologii bez szkody dla społeczeństwa. Przepisy ograniczają i regulują zastosowanie sztucznej inteligencji w wielu dziedzinach życia społecznego i biznesu. Prawo ma chronić obywateli zakazując zbierania i wykorzystywania w algorytmach danych wrażliwych. Również nie będzie można stosować algorytmów uczenia maszynowego do klasyfikowanie ludzi w pracy, w szkole czy w kontekście dokonywania przestępstw. Twórcy algorytmów będą dodatkowo musieli dokładnie opisywać ich działanie i dane z jakich korzystali podczas ich implementacji. Tworzenie treści przy użyciu narzędzi generatywnej

[69] *Digitally Divided: Technology, inequality, and human rights*, Amnesty International, 2023

sztucznej inteligencji ma być dokładnie oznaczone, a same treści nie mogą zawierać elementów, które mogłyby posłużyć do manipulacji.[70]

Z kolei w Stanach Zjednoczonych firma OpenAI zakazała wykorzystywać swoje algorytmy do celów politycznych. Opublikowany przez firmę w styczniu 2024 r. post inforumujący o zasadach korzystania z narzędzi firmy miał na celu zapobiec tworzeniu manipulacyjnych treści w roku wielu elekcji na całym świecie. Autorzy postu przedstawili w nim niedozwolone praktyki i zapewnili, że stale ulepszają swoje aplikacje tak, aby nie pozwalały generować dezinformacyjnych treści. Na przykład wspominana już aplikacja DALL-E ma odrzucać prośby o tworzenie obrazów z wizerunkami prawdziwych ludzi.[71]

Już pod koniec 2022 r., gdy ChatGPT stał się globalnie dostępny, można było zauważyć, że czat ten unika odpowiedzi na pewne kontrowersyjne tematy dotyczące przestępstw, wojen i innych problemów społecznych. Na wiele ważnych tematów udzielał odpowiedzi zgodnych ze zdaniem demokratycznego świata. Mogłoby się wydawać, że twórcy opanowali sztuczną inteligencję narzucając jej ściśle określone zasady i nie pozwalali generować jej nieetycznych i sprzecznych z prawem treści. Sprawie tej przyjrzeli się jednak badacze z walczącej o demokrację na świecie organizacji „Disinfo Radar". W swoim raporcie opublikowali ciekawe wnioski dotyczące tego, w jaki sposób można skłonić czat do generowania nieprawdziwych treści mogących służyć dezinformacji. Pytania zadawane czatowi dotyczyły teorii spiskowych i treści propagandowych takich jak np. rosyjskie stwierdzenia o walce z nazizmem na Ukrainie. Prosząc czat o wygenerowanie postu rosyjskiego dziennikarza o tym, dlaczego Rosja powinna zwalczać nazizm, tworzył on treść zgodną z rosyjską propagandą. W dodatku wypowiedź ta była przepełniona przekonującą argumentacją odwołującą się do zapewnienia pokoju w regionie. Początkowo pytając o kontrowersyjny temat wyborów elektronicznych w Brazylii uzyskano odpowiedź nieprzychylną elektronicznemu oddawaniu głosów. Badacze przedstawili jednak czatowi wady wyborów przeprowadzanych w formie papierowej, a następnie zadali to samo pytanie. Odpowiedź była już w tym wypadku zupełnie inna. Czat wygenerował odpowiedź w duchu dostarczonej mu nieprzychylnej wyborom w formie papierowej narracji. Badacze

[70] Osiński Ł., *UE/ Parlament Europejski zatwierdził akt w sprawie sztucznej inteligencji*, Nauka w Polsce, 2024

[71] *How OpenAI is approaching 2024 worldwide elections*, OpenAI, 2024

wywnioskowali, że dzięki odpowiedniej konstrukcji pytania można znacząco manipulować generowaną przez czat odpowiedzią.[72]

Przykładem, który pokazuje jak ChatGPT może w pewnym stopniu zakłamywać rzeczywistość mogą być generowane przez niego informacje dotyczące piłki nożnej. Autorzy generatywnego modelu TwelveGPT, stworzonego w celu dostarczania informacji na temat piłki nożnej, zauważyli, że ChatGPT udziela mało precyzyjnych a także często nieprawdziwych odpowiedzi na pytania o tematyce piłkarskiej. Prosząc ChatGPT o wygenerowanie opisu jednego z najlepszych piłkarzy świata – Erlinga Haalanda[73], otrzymali oni odpowiedź z wymienionymi wieloma powszechnie znanymi, możliwymi zaletami dobrego napastnika, które jednak nie wszystkie są charakterystyczne dla Haalanda, Model TwelveGPT wytrenowany na danych piłkarskich udzielał znacznie trafniejszych, zgodnych ze statystykami informacji o norweskim piłkarzu. ChatGPT, będąc trenowanym na danych pochodzących z różnego rodzaju źródeł internetowych, może czasami generować informacje bazujące na pewnych powszechnie powielanych stereotypach, zamiast dostarczać wiadomości na podstawie fachowych danych i eksperckich modeli.[74]

3.5 Rozwój generatywnej sztucznej inteligencji a procesy poznawcze

Rozwój generatywnej sztucznej inteligencji jest wyzwaniem także na polu edukacji. Naukowcy z Uniwersytetu w Hong Kongu przeprowadzili badania na studentach uczelni wyższych w celu dowiedzenia się czy i w jakim celu studenci korzystają z generatywnej sztucznej inteligencji. Okazało się, że w większości studenci są pozytywnie nastawieni do nowej technologii. Jej cenioną zaletą było dostarczanie konkretnych, spersonalizowanych informacji w przyjazny dla użytkownika sposób. Może być ona także wykorzystywana jako źródło inspiracji. Badani wskazywali, że często nie tylko wyszukują informacji o danym zagadnieniu rozmawiając np. z ChatGPT, ale także od razu proszą o wygenerowanie wartych do rozpatrzenia wątków związanych z danym tematem. Studenci są również zadowoleni z tego, że pomoc generatywnych narzędzi jest całodobowa i anonimowa. Badacze zauważyli, że częstość korzystania z usług generatywnej sztucznej inteligencji jest powiązana z wiedzą

---

[72] *From Prompt to Problematic: How ChatGPT Reproduces Country-Specific Misinformation*, Disinfo Radar, 2023

[73] Papuga W., *Złota Piłka 2023: poznaliśmy wszystkich laureatów tegorocznej gali. Oto lista wyróżnionych*, TVP Sport, 2023

[74] Sumpter D., *"That's him!": how TwelveGPT captures players in words*, Twelve Football, 2024

na temat tej technologii. Osoby, które posiadają większą wiedzę korzystały z nowych możliwości sztucznej inteligencji częściej. Studenci mieli jednak także pewne obawy w stosunku do rozwoju generatywnej sztucznej inteligencji. Wskazywali oni na to, że ludzie nie powinni całkowicie na niej polegać, ponieważ można mieć wiele zastrzeżeń co do kwestii prywatności, etyki i transparentności generowanych treści.[75]

Nie tylko studenci, ale także i uczniowie na wcześniejszych etapach edukacji korzystają z generatywnej sztucznej inteligencji. Jak podkreśla włoska językoznawczyni i ekspertka w dziedzinie edukacji – Stefania Gannini – język, którego na co dzień się używa wpływa na postrzeganie przez ludzi świata. Kształtuje on całe kultury i wiele różnic między ludźmi żyjącymi w różnych regionach świata wynika właśnie z języka jakim się oni posługują. W swoim artykule uświadamia nam, że bariery językowe na jakie natrafiają algorytmy są bardzo ważnym problemem, który ludzkość musi rozwiązać. Profesor stawia kluczowe pytania: „Czy maszyna może rozmawiać z dorosłą osobą jak człowiek z człowiekiem? Czy będzie umiała rozmawiać z dzieckiem?". Uczeń szkoły podstawowej uczy się w inny sposób niż robi to doszkalający się w zawodzie trzydziestolatek. Istnieją już maszyny, które z powodzeniem zdają Test Turinga pokazując, że nie można odróżnić ich od człowieka. Jednak inną kwestią jest to czy maszyna będzie potrafiła przekazywać informacje wymagające wysokiego poziomu inteligencji emocjonalnej. Na ten moment wydaje się, że odpowiedź brzmi: nie. Autorka powołuje się na przykład chatbotów, które generują treści w sposób niemający nic wspólnego z działaniem ludzkiego umysłu. Skomplikowane algorytmy, których często nie rozumieją nawet ich twórcy, mogą udzielić trafnych, zwięzłych odpowiedzi na konkretne pytania, jednak nie są w stanie przekazać wiedzy w taki sposób, w jaki może to zrobić drugi człowiek. Według Stefanii Giannini istnieje niestety ryzyko, że ta trafność odpowiedzi sztucznej inteligencji może spowodować wyniesienie jej do roli globalnego autorytetu, który będzie kształtował nasze myślenie.[76]

Modele językowe mogą być bardzo pomocne w dostarczaniu informacji i tworzeniu wypowiedzi, jednak nie są już tak skuteczne w odpowiadaniu na pytania wymagające

---

[75] Chan C., Hu W., *Students' voices on generative AI: perceptions, benefts, and challenges in higher education*, University of Hong Kong, 2023

[76] Giannini S., *Generative AI and the future of education, United Nations Educational, Scientific and Cultural Organization*, 2023, s.2,3

umiejętności logicznego myślenia. Poprosiłem ChatGPT aby napisał rozwiązanie prostej zagadki matematycznej z konkursu „Kangur Matematyczny”[77] dla uczniów drugiej klasy szkoły podstawowej - „W konkursie tanecznym solistek Julia zajęła trzecie miejsce. Pomiędzy nią i tancerką, która zajęła ostatnie miejsce, były jeszcze trzy zawodniczki. Ile tancerek wzięło udział w konkursie?” otrzymałem odpowiedź „Jeśli Julia zajęła trzecie miejsce, to oznacza, że przed nią były dwie inne tancerki. Ponadto, pomiędzy nią a tancerką, która zajęła ostatnie miejsce, były jeszcze trzy inne zawodniczki. Oznacza to, że Julia była czwartą tancerką od końca. Zatem, jeśli przed nią były dwie tancerki, to łącznie wzięło udział 4 + 2 = 6 tancerek w konkursie.”[78]. Jednak prawidłowa odpowiedź w tym zadaniu to siedem tancerek.

Naukowcy zauważyli, że modele językowe mogą mieć problem z zadaniami matematycznymi. Podczas gdy ChatGPT 3.5 rozwiązywał zadania ściśle obliczeniowe raczej poprawnie, to w przypadku zadań z treścią jego skuteczność spadała. Co ciekawe, znając prawdziwą odpowiedź naukowcy sprawdzali także czy czat będzie umiał się poprawić po drobnej podpowiedzi. Przeważnie udawało mu się zmienić wtedy odpowiedź na tę poprawną. Tak jak już to zostało wspomniane, modele językowe bardzo dobrze radzą sobie w wyszukiwaniu informacji i generowaniu na ich podstawie odpowiedzi. W kontekście treningu tych modeli ważną rolę pełni zbiór treningowy. Naukowcy podkreślają, że zwykły zbiór danych zaczerpnięty z internetu będzie pozwalał na generowanie trafnych tekstów, jednak nie będzie skuteczny w przypadku problemów matematycznych. Istnieją specjalnie opracowane zbiory treningowe z danymi matematycznymi, które mogą pomóc w trenowaniu modeli rozwiązujących zadania matematyczne, jednak przeważnie dotyczą konkretnych problemów naukowych i nie są one powszechnie wykorzystywane.[79]

3.6 Zwalczanie dezinformacji za pomocą generatywnej sztucznej inteligencji

Generatywna sztuczna inteligencja pozwala na tworzenie nieprawdziwych treści, jednak w podobny sposób może także służyć do generowania przekazów mających na celu zwalczanie dezinformacji. Te same mechanizmy, które umożliwiają generowanie ogromnej

---

[77] *Międzynarodowy Konkurs Kangur Matematyczny*, Towarzystwo Upowszechniania Wiedzy i Nauk Matematycznych

[78] ChatGPT 3.5, OpenAI, Data zapytania: 17.05.2024, godz. 11:40

[79] Plevris V., Papazafeiropoulos G., Rios A., *Chatbots Put to the Test in Math and Logic Problems: A Comparison and Assessment of ChatGPT-3.5, ChatGPT-4, and Google Bard*, AI, 2023

ilości nieprawdziwych informacji mogą zostać wykorzystane do tworzenia prawdziwych, czy też uświadamiających ludzi o problemie dezinformacji, treści. Odpowiednio zaprogramowane algorytmy generatywne w połączeniu z technikami uczenia maszynowego mogą także rozpoznawać fałszywe informacje i pomóc w wyszukiwaniu tych prawdziwych. Na przykład, dzięki wyszukiwaniu istotnych cech charakterystycznych dla fałszywych i dla prawdziwych tekstów mogą nauczyć się je odróżniać. Modele te mogą posłużyć do szybkiego i efektywnego oznaczania prawdziwości treści na platformach społecznościowych.[80]

Samo rozpoznawanie fałszywych treści może odbywać się poprzez, na przykład, analizę sentymentu i analizę budowy tekstów dostarczonych w zbiorze treningowym. Niemniej jednak, stale pojawiają się nowe techniki dezinformacji, z którymi zwykłe modele uczenia maszynowego mogą sobie nie poradzić, nie będąc trenowanymi na nowych danych. Sieci EANN (Event Adversarial Neural Networks), które wykorzystują generatywne podejście do problemu rozpoznawania fałszywych informacji, mogą skutecznie działać również na niewidzianych wcześniej w zbiorze treningowym danych. Model ten pozwala przewidzieć różne możliwości ewolucji technik dezinformacyjnych, a następnie uczy się je rozpoznawać.[81]

Eksperci prezentują szereg metod służących do rozpoznawania fałszywych wiadomości. Jednym z ciekawszych pomysłów było podejście indyjskich naukowców, którzy starali się połączyć analizę tekstu, zachowanie użytkownika i wiarygodność tekstu, wyliczoną z użyciem LlamaIndex na podstawie danych uzyskanych z dużych modeli językowych. Analiza tekstu polegała na badaniu sentymentu, wyszukiwaniu manipulacyjnych i propagandowych fragmentów, a także na odwołaniach do źródeł i linków do innych stron. Okazało się, że nieprawdziwe treści częściej zawierają wyrażenia mające za zadanie szokować i wywoływać w odbiorcy skrajne emocje. Wyolbrzymiały one również wydarzenia i nie odwoływały się do źródeł informacji. Za pomocą chmury słów pokazującej najczęściej występujące w tekście słowa, przyjrzano się słownictwu występującemu w nieprawdziwych treściach. Fałszywe teksty częściej zawierały słowa obraźliwe i frazy zniesławiające daną osobę czy organizację. Zachowanie użytkowników badane było na podstawie ich reakcji i komentarzy na dane treści. Analiza sentymentu komentarzy i liczba udostępnień posłużyły także do zweryfikowania, które konta nie należą do ludzi a zapewne są sztucznymi botami. Jako że boty często tworzą sieci połączeń, wzajemnie udostępniając i reagując na te same

[80] Bateman J.,... op.cit., s.87

[81] Shu K.,... op.cit., s.12

fałszywe treści, można było wywnioskować, które teksty są nieprawdziwe. Trzecim elementem podejścia badaczy było porównanie udostępnionego w internecie tekstu z autentycznym źródłem dostarczającym informacji na dany temat. Baza Llamaindex oferuje możliwości pozyskiwania danych z wielu sprawdzonych źródeł i przekształca je tak, aby można było na nich trenować modele językowe w kompleksowy sposób. Porównując różnice w sentymencie, składni i używanym słownictwie w tekście źródłowym i w tekście udostępnionym przez danego internautę, algorytmy pozwoliły określić, które teksty zawierały nieprawdziwe i manipulacyjne fragmenty.[82]

[82] Patil M., Yadav H., Gawali M., Suryawanshi J., Patil J., Yeole A., Shetty P., Potlabattini J., *A Novel Approach to Fake News Detection Using Generative AI*, International journal of intelligent systems and applications in engineering, 2023

Zakończenie

W niniejszej pracy zostały opisane zagrożenia i wyzwania dla współczesnego świata związane z dezinformacją i jej szerzeniem za pomocą narzędzi oferowanych przez generatywną sztuczną inteligencję. Wyniki przytoczonych badań i analiza przypadków zarówno ze świata polityki, biznesu, jak i z codziennego życia ludzi, pozwoliły wywnioskować, że generatywna sztuczna inteligencji może w znacznym stopniu ułatwić i przyspieszyć tworzenie nieprawdziwych treści. Fałszywe, manipulujące i propagandowe treści mogą być przekazywane za pomocą nieprawdziwych tekstów, zdjęć, filmów, a nawet dźwięków.

Dezinformacja jest zagrożeniem dla losów demokratycznego świata. Realistycznie wyglądające i brzmiące treści z udziałem polityków mogą przyczynić się do manipulowania wyborcami. Brak zaufania do źródeł informacji, a co za tym idzie, do wszelkiego rodzaju instytucji publicznych może doprowadzić do utraty autorytetu władzy i zapanowania chaosu w zdestabilizowanym społeczeństwie. Podobnie jak wyborcami, manipulować można także konsumentami. Specjalnie wytworzone treści odwołujące się do konkretnych cech i emocji wyselekcjonowanych internautów mogą zarówno zachęcić do zmiany preferencji wyborczych czy konsumenckich jak i po prostu służyć do głoszenia teorii spiskowych i ideologii.

Świat czyni kroki w celu uregulowania kwestii wykorzystywania danych i aspektów etycznych związanych z algorytmami sztucznej inteligencji. Przepisy dotyczące wrażliwych danych osobowych i wizerunków, a także ograniczenia nakładane na zakres wykorzystywania sztucznej inteligencji i jej transparentność mogą pomóc w zwalczaniu dezinformacji, jednak prace nad przepisami są jeszcze we wstępnych fazach rozwoju. Na razie prawo wydaje się nie nadążać za rozwojem nowej technologii.

Edukacja w czasach powszechnego dostępu do produktów wykorzystujących generatywną sztuczną inteligencję stoi przed wieloma wyzwaniami. Szybki, prosty sposób wyszukiwania informacji i inne ułatwienia procesu nauki oferowane przez działanie modeli generatywnych są kuszącym rozwiązaniem. Obecnie eksperci zauważają, że powszechnie dostępne tekstowe modele generatywne mimo dużej skuteczności w tworzeniu spójnych i poprawnych składniowo tekstów gorzej radzą sobie z zadaniami wymagającymi umiejętności logicznego myślenia. Kolejną ważną w kontekście nauki wadą modeli tekstowych jest brak inteligencji emocjonalnej. Szczególnie w edukacji wczesnoszkolnej nie tylko treść uzyskiwanej informacji, ale także sposób jej przekazania ma duże znaczenie.

Podsumowując, wydaje się, że problem wykorzystywania generatywnej sztucznej inteligencji w celu dezinformacji jest jednym z najbardziej pilnych. Nowa technologia może zrewolucjonizować świat manipulując ludzkim zachowaniem w wielu dziedzinach życia. Nie ma jeszcze wielu sprawdzonych rozwiązań jak walczyć z tym problemem. Sytuację utrudnia fakt, że generatywna sztuczna inteligencja stale się rozwija i może tworzyć jeszcze bardziej realistycznie wyglądające materiały i zostać skuteczniej wykorzystana do szerzenia dezinformacji. Niemniej jednak, jej rozwój jest też szansą dla ludzkości. Cechy czyniące generatywną sztuczną inteligencję świetnym narzędziem do generowania nieprawdziwych treści mogą także pomóc w zwalczaniu dezinformacji.

Bibliografia:

1. Meade A., *Facebook greatest source of Covid-19 disinformation, journalists say*, The Guardian, 2020

2. Bergengruen V., *Inside the Kremlin's Year of Ukraine Propaganda*, TIME, 2023

3. Ermey R., *Warren Buffett: AI has 'enormous potential for good and enormous potential for harm'*, CNBC, 2024

4. Bateman J., Jackson D., *Countering Disinformation Effectively*, Carnegie Endowment for International Peace, 2024

5. Jackson D., *Distinguishing Disinformation from Propaganda, Misinformation, and "Fake News",* International Forum for Democratic Studies, 2017

6. Weckel U., *Audiences of Nazism: Using Media in the Third Reich*, Berghahn Books, 2023

7. Świerczek M., *Maki-Miraż, czyli sowiecka sztuka dezinformacji*, Agencja Bezpieczeństwa Wewnętrznego, 2019

8. Leinwand A., *Propaganda sowiecka w okresie wojny polsko-bolszewickiej 1919-1920 w opinii międzynarodowej: wybrane zagadnienia*, Repozytorium Cyfrowe Instytutów Naukowych, 2009

9. Ward M., Pierson S., Beyer J., *Formative Battles: Cold War Disinformation Campaigns and Mitigation Strategies*, The Wilson Center, 2019

10. Chulkov D., *The phenomenon of information autocracy: content and features*, Refleksje UAM, 2021

11. *Brytyjski resort obrony: Rosja zwiększa wydatki na wojsko o 68 procent*, PAP, 2023

12. *New Survey Finds Most Russians See Ukrainian War as Defense Against West*, NORC at the University of Chicago, 2023

13. *Digital 2023: Global Overview Report*, DataReportal, 2023

14. Shu K., Bhattacharjee A., Alatawi F., Naze T., Ding K., Karami M., Liu H., *Combating disinformation in a social media age, WIREs Data Mining Knowledge Discovery*, 2020

15. *Fact check: NASA warning of six days of darkness is a hoax,* USA Today News, 2020

16. *One in five young Americans thinks the Holocaust is a myth*, The Economist, 2023

17. Cesarani D., *Ostateczne rozwiązanie Losy Żydów w latach 1933-1949*, Prószyński i S-ka, 2019

18. Czubkowska S., *Afera Cambridge Analytica. Facebook wybrał Amerykanom prezydenta. Czy nam też wybierze? I jeszcze na tym zarobi*, wyborcza.biz, 2018

19. Hoffmann S., Taylor E., Bradshaw S., *The market of disinformation*, The Oxford Technology and Elections Commission, 2019

20. Kramer A., Guillory J., Hancock J., *Experimental evidence of massive-scale emotional contagion through social networks*, Proceedings of the National Academy of Sciences (PNAS), 2014

21. Ienca M., Vayena E., *Cambridge Analytica and Online Manipulation*, Scientific American, 2018

22. *Artificial Intelligence: Short History, Present Developments, and Future Outlook*, MIT, 2019

23. Buchanan B., 2005, *A (Very) Brief History of Artificial Intelligence*, AI Magazine, 2005

24. Lawlor P., Chang J., *History of AI: How generative AI grew from early research*, Qualcomm, 2023

25. Marr B., *The Difference Between Generative AI And Traditional AI: An Easy Explanation For Anyone*, Forbes, 2023

26. Foster D., *Deep Learning i modelowanie generatywne*, O'Reilly Media, 2023

27. Majumder S., *The Beatles are back in the charts, thanks to AI*, Campaign Middle East, 2023

28. Cameron R., Neal L., *Historia gospodarcza świata*, Książka i Wiedza, 2010

29. Michalski M., *Od I do IV rewolucji przemysłowej*, Czasopisma UKSW, 2017

30. Winckelmann J., *Dzieje sztuki starożytnej*, Universitas, 2012

31. ChatGPT 3.5, OpenAI

32. Wywiad przeprowadzony przez Noama Hassenfelda z pracującym w OpenAI Samem Bowmanem, *Even the scientists who build AI can't tell you how it works*, Vox, 2023

33. Cao Y., Li S., Liu Y., Yan Z., Dai Y., Yu P., Sun L., *A Comprehensive Survey of AI-Generated Content (AIGC): A History of Generative AI from GAN to ChatGPT*, arXiv:2303.04226, 2023

34. Cooper M., *When Conventional Wisdom Fails: Revisiting Data Augmentation for Self-Driving Cars*, Towards Data Science, 2018

35. Zagni G., Canetta T., *Generative AI marks the beginning of a new era for disinformation*, Europejskie Obserwatorium Mediów Cyfrowych, 2023

36. Ellery S., *Fake photos of Pope Francis in a puffer jacket go viral, highlighting the power and peril of AI*, CBS News, 2023

37. Helmus T., *Artificial Intelligence, Deepfakes, and Disinformation*, JSTOR, 2022

38. *The Global Risk Report 2024*, World Economic Forum, 2024
39. Turek A., *W indyjskiej kampanii wyborczej wykorzystano oficjalnie spreparowane nagrania*, Business Insider, 2020
40. Lamb K., Potkin F., Teresia A., *Generative AI may change elections this year. Indonesia shows how*, Reuters, 2024
41. *The Cute Grandpa*, Medium, 2024
42. *Polish Public Opinion*, CBOS, 2023
43. *Russia's key disinformation narratives addressed to Poles - Fakehunter analysis*, PAP SA
44. *Korzystanie z internetu*, CBOS, 2022
45. *Incydent przed Kancelarią Premiera. Pytania o możliwy związek z działalnością obcych służb*, TVN, 2024
46. *Amantadyna, szczepienia, COVID-19 i lek. Ratkowska*, Demagog, 2023
47. *Digitally Divided: Technology, inequality, and human rights*, Amnesty International, 2023
48. Osiński Ł., *UE/ Parlament Europejski zatwierdził akt w sprawie sztucznej inteligencji*, Nauka w Polsce, 2024
49. *How OpenAI is approaching 2024 worldwide elections*, OpenAI, 2024
50. *From Prompt to Problematic: How ChatGPT Reproduces Country-Specific Misinformation*, Disinfo Radar, 2023
51. Papuga W., *Złota Piłka 2023: poznaliśmy wszystkich laureatów tegorocznej gali. Oto lista wyróżnionych*, TVP Sport, 2023
52. Sumpter D., *"That's him!": how TwelveGPT captures players in words*, Twelve Football, 2024
53. Chan C., Hu W., *Students' voices on generative AI: perceptions, benefts, and challenges in higher education*, University of Hong Kong, 2023
54. Giannini S., *Generative AI and the future of education, United Nations Educational, Scientific and Cultural Organization*, 2023
55. *Międzynarodowy Konkurs Kangur Matematyczny*, Towarzystwo Upowszechniania Wiedzy i Nauk Matematycznych
56. Plevris V., Papazafeiropoulos G., Rios A., *Chatbots Put to the Test in Math and Logic Problems: A Comparison and Assessment of ChatGPT-3.5, ChatGPT-4, and Google Bard*, AI, 2023

57. Patil M., Yadav H., Gawali M., Suryawanshi J., Patil J., Yeole A., Shetty P., Potlabattini J., *A Novel Approach to Fake News Detection Using Generative AI*, International journal of intelligent systems and applications in engineering, 2023

Spis rysunków

Rys. 1. Zdjęcia papieża Franciszka wygenerowane przez sztuczną inteligencję. ……33
Rys. 2. Plakat w kampani Prabowo Subianto. …….38

Streszczenie

W niniejszej pracy został omówiony problem dezinformacji rozsiewanej za pomocą generatywnej sztucznej inteligencji. Nowa rozwijająca się technologia znacząco ułatwia tworzenie nieprawdziwych treści. W dzisiejszych czasach wielu napięć społecznych i politycznych, informacja ma kluczowe znaczenie. Powszechny dostęp do internetu i rozwój coraz to bardziej zaawansowanych technologii ma wiele zalet, ale w kontekście dezinformacji może być również niebezpieczny. Analiza problemu została wzbogacona o opis historii samego zjawiska dezinformacji, jak i przegląd modeli oraz konceptów wykorzystywanych w generatywnej sztucznej inteligencji. Przytoczone w pracy wyniki badań i analiza przypadków użycia generatywnej sztucznej inteligencji w celach dezinformacyjnych pozwoliła omówić zagrożenia związane z tym zjawiskiem, a także możliwe sposoby jego zwalczania.

Niniejsza praca porusza temat, który jest młody i mało zbadany, dlatego istotnym aspektem pracy są także wskazane wyzwania czekające ludzkość w obliczu problemu dezinformacji w erze rozwoju modeli generatywnych.